

首都师范大学
本科生毕业论文（设计）

面向城市遥感的 Sentinel-2 图像超
分辨率方法对比与应用
—— 以北京东南城区为例

**Comparative Study and Application of
Super-Resolution Methods for Urban
Remote Sensing Using Sentinel-2 Data:
A Case Study of Southeastern Beijing**

院 系 资源环境与旅游学院
专 业 遥感科学与技术
年 级 21 级
学 号 1213604001
指导教师 张爱武
论文作者 王楚涵

首都师范大学本科生毕业论文（设计）原创性承诺书

论文（设计）题 目		面向城市遥感的 Sentinel-2 图像超分辨率方法对比 与应用 —— 以北京东南城区为例		
学生姓名	王楚涵		专业	遥感科学与技术
学号	1213604001		完成时间	年 月 日 ~ 年 月 日
指导教师姓名		张爱武	职 称	教授
承诺内容： 1、本毕业论文（设计）是学生 王楚涵 在导师 张爱武 的指导下独立完成，凡涉及其他作者的观点和材料，均作了注释，如出现抄袭及侵犯他人知识产权的情况，愿按学校有关规定接受处理，并承担相应责任。 2、学校有权保留并向上级有关部门送交本毕业论文(设计)的复印件和磁盘。 备注：				
学生签名： 时间：				

说明：学生毕业论文（设计）如有保密等要求，请在备注中明确，承诺内容第 2 条即以备注为准。

中文摘要

随着城市化进程加快,中等分辨率遥感影像在城市地表精细识别中的局限性日益突出。针对 Sentinel-2 多波段分辨率不一致的问题,本文构建统一的人工退化评估框架,系统比较六种典型超分方法(Bicubic、Brovey、PCA、Random Forest、ATPRK、DSen2)在城市遥感中的适用性,并基于 PSNR、SSIM、SAM、RMSE 等指标进行定量评估。结果表明,DSen2 在空间结构与光谱一致性方面表现最佳,适合纹理复杂区域;ATPRK 则具备较强光谱保真度,适用于边界清晰区域。进一步将 DSen2 应用于北京东南城区 2017 - 2024 年多期 Sentinel-2 影像,开展生态指数(RSEI)与不透水面指数(ENDISI)提取与时序分析。对比结果显示,超分处理显著提升了遥感指数精度,DSen2 提取结果与 Landsat-8 构建的准真实图像最为接近。研究为城市遥感数据的高质量重建提供方法支撑,也为生态监测与城市发展决策提供了有力参考。

关键词: Sentinel-2; 图像超分辨率; 深度学习; 城市遥感; 生态指数; ENDISI

Abstract

With the acceleration of urbanization, the limitations of medium-resolution remote sensing imagery in fine-scale urban surface monitoring are becoming increasingly evident. To address the inconsistent spatial resolutions among Sentinel-2 spectral bands, this study proposes a unified artificial degradation-based evaluation framework and systematically compares six representative super-resolution (SR) methods—Bicubic, Brovey, PCA (and its optimized version), Random Forest, ATPRK, and DSen2—within urban remote sensing scenarios. Using a 600×600 sample area in urban Beijing, a simulated 40m-to-20m SR task is performed, and model performance is quantitatively assessed via PSNR, SSIM, SAM, and RMSE. Results show that DSen2 achieves superior performance in spatial detail recovery and spectral consistency, while ATPRK offers high spectral fidelity without requiring training data, making it suitable for structured urban-edge areas. The DSen2 model is further applied to multi-temporal Sentinel-2 imagery (2017–2024) of southeastern Beijing, extracting RSEI and ENDISI indices to analyze ecological change and urban expansion. Super-resolution processing significantly improves the accuracy and boundary clarity of index extraction, with DSen2 producing results most consistent with pan-sharpened Landsat-8 reference imagery. This study provides a methodological reference for high-quality urban image reconstruction and supports ecological monitoring and sustainable urban planning.

Keywords: Sentinel-2; super-resolution; deep learning; urban remote sensing; RSEI; impervious surface; ENDISI

目 录

第一章 引言	1
1.1 研究背景与意义	1
1.2 研究现状综述	1
1.3 研究目标	2
第二章 数据与研究区	3
2.1 研究区域（北京大兴区及扩展区域）	3
2.2 数据来源与预处理	3
2.3 指标选取和实现工具	4
第三章 方法	6
3.1 总体技术路线	6
3.2 评估框架设计	6
3.3 各超分方法的实现过程	6
3.3.1 传统方法.....	7
3.3.2 机器学习方法	10
3.3.3 深度学习方法	10
第四章 结果	12
4.1 定量指标对比（PSNR、SSIM、SAM、RMSE）	12
4.1.1 单波段讨论（以B05波段为例）	13
4.1.2 多波段指标稳定性分析	14
4.1.3 PCA潜能以及波段相关度展示.....	15
4.2 可视化对比	16
4.3 光谱一致性分析	20

4.4 方法优劣总结	23
4.5 城市时序变化应用分析	23
第五章 讨论	27
5.1 评估流程的潜在短板	27
5.2 PCA 融合方法的劣势分析以及现阶段的超分方法研究趋势 ..	28
5.3 方法在不同地物类型上的适应性表现分析	28
5.4 生态指数	29
第六章 总结	30
参考文献.....	32
附录 A: ATPRK 超分辨率方法的 MATLAB 实现	33
致谢	336

第一章 引言

1.1 研究背景与意义

遥感技术是现代城市监测与区域生态评估中不可或缺的重要工具，能够持续获取大范围、时序一致的地表信息。在众多遥感数据源中，Sentinel-2 卫星因其较高的时间分辨率（5 天重访）和多波段成像能力，广泛应用于城市扩张、土地覆被变化、生态环境评估等领域[1]。Sentinel-2 提供 13 个光谱波段，涵盖可见光、近红外和短波红外，空间分辨率为 10m、20m 和 60m 不等。然而，波段分辨率不统一的问题显著增加了多波段融合和指数计算（如 NDVI、NDBSI、RSEI 等）的复杂性，降低了城市地物的提取精度，尤其在建筑密集、纹理细节丰富的城市区域更为明显。例如，李伟等（2020）指出，遥感影像的空间一致性对于地物精细提取具有重要影响，分辨率不一致会直接影响城市遥感应用的精度与可靠性[2]。

为提升遥感影像在城市区域的适用性，近年来研究者提出了多种图像超分辨率重建（Super-Resolution, SR）方法，旨在统一各波段至更高的空间分辨率，从而提高图像的空间表达力与光谱一致性，为城市遥感解译和时序变化分析提供高质量数据支持，如增强遥感指数的计算精度以及提升影像质量。遥感生态指数（RSEI）集成了 NDVI、湿度、地表温度等多个要素，是城市生态环境动态评估的核心指标；不透水面指数（ENDISI）则用于反映城市建设强度，是衡量城市扩张和生态压力的重要参数且高度依赖于多波段的光谱一致性和空间分辨率。因此，提升空间一致性的超分辨率处理，已成为 RSEI 与 ENDISI 等生态指数高精度时序分析的重要支撑手段。

1.2 研究现状综述

纵观近十年来遥感影像超分辨率技术发展，本文将其主要分为三大类，传统图像融合方法、机器学习方法与深度学习方法：

(1) 传统图像融合方法：主成分分析（PCA）、Brovey 变换等，属于无监督的空间变换模型。如 Gharbia 等人[3]提出了的 Brovey 变换的遥感融合图像方法优势在于计算效率高、可解释性强，但存在过度增强空间细节、损失光谱信息的问题。在城市区域中，由于混合像素和复杂纹理较多，传统方法往往无法很好地保持建筑、绿地等地物的光谱一致性。

(2) 机器学习方法：随机森林（RF）、支持向量机（SVM）等被广泛应用于多源遥感影像超分与分类任务。然而，这类方法对训练样本的数量、分布及质量高度敏感，模型的泛化能力存在限制。Shermeyer 和 Van Etten（2019）指出：“基于某一地区影像训练的模型，往往难以适用于其他地区的数据”，其根本原因在于不同地区遥感影像在数据统计特性上的差异，导致模型迁移性能不足[4]。

(3) 深度学习方法：如 SRCNN、VDSR、DSen2 等端到端卷积神经网络，已成为遥感影像超分的研究热点。特别是 Lanaras 等人[5]提出的 DSen2，针对 Sentinel-2 的多分辨率问题，设计了具备全球泛化能力的残差学习架构，可在保持反射率的前提下显著增强空间分辨率。这些模型能在城市环境中对复杂的建筑纹理和街道线状地物实现更精细的重建，在光谱一致性和视觉效果方面均表现出色。

尽管深度学习的超分辨率方法在城市遥感中表现出卓越性能，但在某些特定场景下仍面临挑战。例如，成科扬等人[6]对该类方法的遥感应用进行了系统梳理，指出在训练数据稀缺、地物特征复杂的区域（如极地）中，模型性能可能受到一定限制。而在农田或自然生态区域，由于地物结构相对简单、光谱差异明显，即便不采用复杂的深度学习网络，也能够实现较理想的超分辨率重建效果。

在传统超分方法中，有研究表明，ATPRK (Area-to-Point Regression Kriging) 方法因其结合了地统计建模与回归残差校正机制，在城市与乡村区域均表现出良好的泛化性[7]。在多个城市研究中，ATPRK 在空间一致性和波段重建质量之间取得了较好的平衡，其性能与深度学习方法相近，但训练复杂度和计算开销更低，适用于区域级大面积制图任务。

因此，不同地理环境对超分方法提出了差异化的要求：

- **城市区域：**建筑结构复杂，推荐使用深度学习模型（如 DSen2）以恢复空间细节；
- **农村与自然区域：**光谱区分度高，适宜使用传统融合或统计方法（如 PCA、ATPRK）以保留光谱特性；
- **极地与冰雪区：**需引入多尺度建模或多源数据融合方法，增强模型稳定性与泛化能力。

当前大多数超分方法研究集中于图像层面的定量评价，如 PSNR、SSIM、SAM 等指标。本研究在此基础上引入实际应用环节，重点分析不同超分方法对城市遥感指数提取的影响。为实现统一、可比的性能评估，本文采用人工退化重建评估框架 (Wald's protocol)，通过将原始 20m 图像降采样至 40m，再重建回 20m 与原图对比，从而模拟真实应用情境下各方法的表现差异。进一步地，结合生态指数 (RSEI) 与不透水面指数 (ENDISI) 的提取效果，验证重建图像在城市扩张与生态监测中的实际应用价值，填补当前研究中缺乏遥感业务场景实证验证的不足。

1.3 研究目标

针对当前遥感图像超分辨率方法在城市应用中的性能差异与评估不足问题，本文聚焦以下两个核心目标：

- (1) 确定适用于城市区域的最优超分方法，为高精度遥感解译提供数据支持。构建统一的模拟退化评估框架，系统比较 Bicubic、PCA、Brovey、Random Forest、ATPRK 与 DSen2 等六种典型方法在城市场景下的重建性能，通过 PSNR、SSIM、SAM 等指标量化其空间细节增强与光谱一致性表现，明确最优策略，服务于地物识别与生态监测等需求。
- (2) 验证最优方法在城市遥感应用中的实际价值。以北京东南城区为案例，基于最优方法生成的高分辨率图像，开展多期生态指数 (RSEI) 与不透水指数 (ENDISI) 提取分析，结合原始图像与其他方法结果进行对比，评估其在城市扩张与生态演变识别中的精度与实用性，验证其在遥感业务中的推广潜力。

第二章 数据与研究区

2.1 研究区域（北京大兴区及扩展区域）

本研究选取北京市大兴区亦庄与朝阳交界的高密度城市扩张带作为主要研究区域（见图1）。该区域地理范围位于经纬度框[116.48, 39.78, 116.63, 39.93]，包括亦庄北部工业开发区、临空经济圈及朝阳东南部新兴居住区。近年来，该区域作为北京“南部扩展”与“东部疏解”双重发展策略的交汇地带，城镇化进程尤为显著，典型地表现出多类型地物并存、不透水层迅速增长的特征。在遥感研究中，该区域已被频繁用于城市扩张、生态演变、热岛效应等议题的实证分析，被认为是典型的快速城市化敏感区之一[8]。

本研究中，该区域为城市扩张分析的数据源。算法评估阶段选取了其一块 600×600 像素块的子区域作为实验样本，用于不同超分方法的性能对比。该子区域具备结构复杂、地物多样、水体清晰的优势，适宜评估各类超分模型在城市遥感中的应用能力。

鉴于 Sentinel-2 卫星影像具备多光谱、高时空分辨率、免费开放等优势，成为本研究主要数据源。然而如引言所述，Sentinel-2 波段空间分辨率不一（部分波段为 20m 或 60m），导致在生态分析、城市分类中常出现空间信息不足、指数表达不一致等问题。因此，统一图像分辨率已成为研究的关键前提[9]。

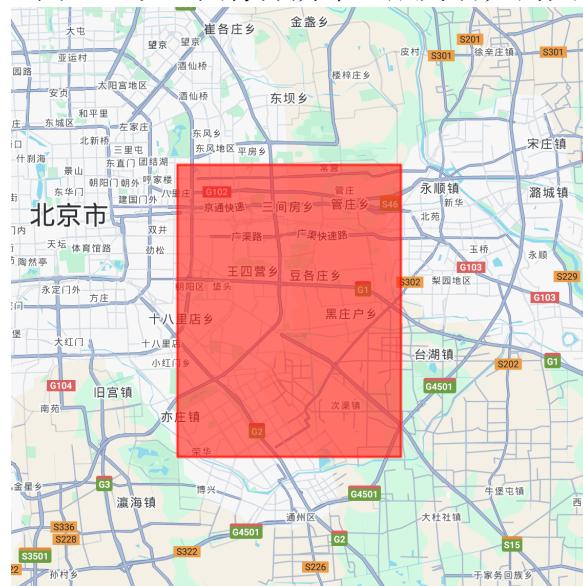


图 1 研究区域

2.2 数据来源与预处理

本研究所使用的遥感数据来自哥白尼计划(Copernicus Programme)开放获取的 Sentinel-2 卫星影像。具体产品为 Level-2A (L2A) 大气校正后地表反射率产品，涵盖 13 个光谱波段，空间分辨率分别为 10m、20m 和 60m。每幅影像以 Tile (网格块) 为单位组织，研究区对应的 Tile 编号为 T50TMK，其空间覆盖约为 100km×100km，涵盖了北京市中心至东南部区域的主要城市建设带。

为确保时间序列分析的可比性，选取了 2017、2019、2022 和 2024 年 6 月中旬的 L2A 产品，全部为夏季同季节、云量控制在 10% 以下的影像，从而最大限度减少季节性、辐射差异和大气扰动的影响。数据下载通过 [Copernicus Open](#)

[Access Hub](#) 实现，后续图像的裁剪与感兴趣区域（AOI）提取在 Google Earth Engine (GEE) 平台上完成，确保所有图像边界严格限定在研究区域范围内。

针对原始 20m 空间分辨率的波段 (B05、B06、B07、B8A、B11、B12)，本研究参考众多超分重建验证策略，如 Armannsson 等人的研究，使用 Python 环境中的 Rasterio 与 OpenCV 库进行降采样处理。采用双线性插值法将 20m 波段缩放至 40m，以构造模拟的低分辨率影像数据，作为后续超分辨率重建方法的输入基础。处理完成的图像统一保存为 tif 格式，并重投影至 WGS 84 / UTM Zone 50N (EPSG:32650) 便于统一处理和对比分析。

此外，为了对超分辨率重建方法的应用价值进行实证验证，本文引入 Landsat-8 卫星影像作为真实参考图像。Landsat-8 由美国地质调查局 (USGS) 发布，其光学遥感数据具备全球覆盖能力，主传感器 OLI 提供 30m 分辨率的多光谱影像，并配备一条 15m 分辨率的全色波段 (Band 8)，常用于图像增强与空间细节提取。参考相关研究中的通用流程，本文采用以下方法构建参考图像：

1. 首先获取覆盖研究区的 Landsat-8 影像，时间为 2024 年 6 月 17 日（与对比的哨兵影像在相近时间）。
2. 对全色波段 (B8) 与多光谱波段进行 Pan-sharpening 融合处理，提升图像空间分辨率。
3. 再将融合结果通过 Bicubic 插值方式重采样至 10m 分辨率，使其在空间尺度上接近 Sentinel-2 超分图像，用于评估超分重建后的精度提升。

虽然 Landsat-8 的原始分辨率并非真正的 10m，但通过 Pan-sharpening 与重采样后的图像可在一定程度上近似反映地物真实值。在当前缺乏地面实测或更高分辨率影像的条件下，具备良好的“准真实参考”价值。

2.3 指标选取和实现工具

为客观评估不同超分辨率重建方法的性能，本研究借鉴 Dong 等人 [10] 和 Armannsson 等人研究先例，选用以下空间与光谱指标进行定量评估（如表 1）：

表 1 方法定量指标一览

Index	一般范围	说明
PSNR (Peak Signal-to-Noise Ratio)	大概 20-50dB	衡量图像整体重建误差，值越高表示质量越好
SSIM (Structural Similarity Index)	[0,1]	衡量图像结构、亮度、对比度一致性
SAM (Spectral Angle Mapper)	大概 0- 30°	测量高维光谱向量间夹角，越小表示光谱保真度越高。
RMSE (Root Mean Square Error)	[0, 10000)	预测值与真实值之间的偏差，越小代表偏差越小。

在城市扩张分析部分，本文采用本研究引入两个遥感指数：ENDISI 与生态环境指数 (RSEI)。

ENDISI 由 Chen 等人 [10] 提出，是当前性能最优的城市不透水层指数之一。它结合了植被、水体、建筑物等典型地物的光谱特征，显著增强城市与非城市地表的区分能力，适用于高密度建成区与城市边缘带变化监测。其定义为：

$$\text{ENDISI} = \frac{(NDBI-NDVI)-(MNDWI)}{(NDBI-NDVI)+(MNDWI)} \quad (\text{式 1})$$

其中：

- $NDBI = (B11 - B8) / (B11 + B8)$
- $NDVI = (B8 - B4) / (B8 + B4)$
- $MNDWI = (B3 - B11) / (B3 + B11)$

RSEI 是一个综合反映区域生态质量的遥感指数，最早由徐涵秋（2013）[13] 提出，整合了归一化植被指数（NDVI）、湿度分量（WET）、裸地指数（NDBSI）与地表温度（LST），进行主成分分析得到第一主成分作为生态质量代表。本研究因缺乏 LST 数据，采用简化版 RSEI（RSEI_noLST）：

$$RSEI_{noLST} = PCA_1(NDVI, WET, NDBSI) \quad (\text{式 2})$$

本研究综合利用以下技术平台进行数据处理与分析：

- **Python 与 MATLAB:** 用于图像降采样、重建方法实现与定量指标计算。其中，MATLAB 主要用于 ATPRK 方法的处理，得益于其在大矩阵计算与地统计建模方面的高效性能；
- **Google Earth Engine (GEE):** 负责遥感影像的下载、波段提取、研究区掩膜裁剪等预处理操作；同时，用于获取 Landsat-8 影像并完成参考图像的构建。具体地，调用 Landsat-8 Collection 2 Level-2 产品中的多光谱波段（30m）与全色波段（15m），通过 Pan-sharpening 融合与 Bicubic 重采样处理生成 10m 分辨率的“准真实参考图像”，用于验证优秀超分方法在指数提取与空间结构表达中的表现提升。
- **QGIS 与 ENVI:** 用于影像的可视化、波段合成与伪彩色渲染，以及融合结果的直观比对和地图输出。

第三章 方法

3.1 总体技术路线

本研究整体流程如图 2 所示。首先，基于 Sentinel-2 20m 分辨率波段构建人工退化模拟数据集，通过降采样至 40m 后恢复到 20m，评估六种不同超分方法（Bicubic、Brovey、PCA、Random Forest、ATPRK、DSen2）。随后，基于 PSNR、SSIM、RMSE、SAM 指标，综合定量与定性分析，优选性能最优方法。最后，将最佳方法应用于北京市亦庄-朝阳区域 2017 - 2024 年多期影像，提取高分辨率 RSEI 和 ENDISI 指数并开展城市扩张与生态变化分析。为验证其在城市遥感应用中的增益效果，进一步与原始图像、典型低效方法及准真实的 10m 重采样影像进行了对比分析。

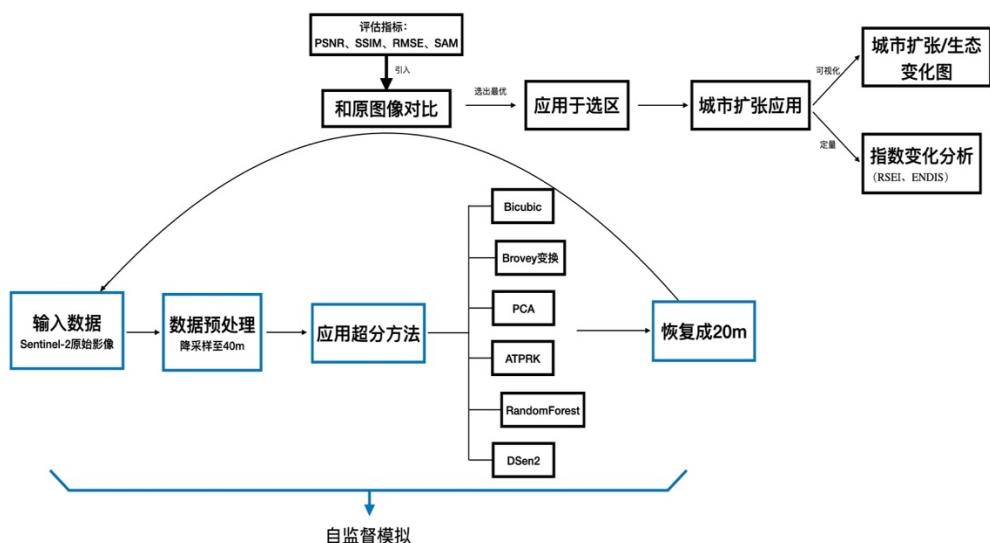


图 2 研究总体技术路线图

3.2 评估框架设计

考虑到 Sentinel-2 卫星的部分波段（如 B05 - B12）在真实场景中并无对应的 10m 分辨率 Ground Truth，本文借鉴 Armannsson 等人提出的“Wald’s Protocol”，即人工退化重建评估框架，构建训练与评估框架。具体流程为：首先将裁剪得到的 600×600 尺寸原始 20m 波段影像（Degraded_GT_clip）降采样至 40m（Degraded_GT_clip_40m），作为模拟的低分辨率输入；随后应用不同超分方法将其恢复到 20m，并与未降采样的原始影像进行比对。为验证超分效果，采用 RMSE、PSNR、SSIM、SAM 多种空间与光谱指标进行定量分析，并结合视觉效果与假彩色图像进行主观评估。最终选取最优方法，应用于多期 Sentinel-2 数据的真实超分及城市不透水层提取分析中，目的为揭示更多北京近些年来城市变化，同时也验证优选超分方法的实用性。

3.3 各超分方法的实现过程

表 2 各方法所选引导波段说明

方法类型	方法名称	引导波段（高分辨率波段）选取
插值法	Bicubic	无
融合方法	Brovey	B2, B3, B4
融合方法	PCA	B2, B3, B4
融合方法（方案 1 优化）	PCA（相关性波段引导）	通过 Pearson 相关性分析后最相关的单个高分辨率波段
融合方法（方案 2 优化）	PCA（引入加权）	B2, B3, B4 + 最相关的单个高分辨率波段
地统计模型	ATPRK	B2, B3, B4
机器学习	Random Forest	B2, B3, B4
深度学习	DSen2	B2, B3, B4, B8, B5-12

超分辨率处理的核心思想是借助高空间分辨率波段的信息，引导低分辨率波段进行细节恢复。在 Sentinel-2 卫星影像中，通常将空间分辨率为 10m 的高分波段（B02、B03、B04 和 B08）作为引导源，用于辅助对 20m 波段（如 B05 - B12）的超分重建。根据不同方法的原理与设计，其引导策略可归纳为以下几类：

1. 基于单波段相关性引导：如本文提出的优化型 PCA 方法，基于 Pearson 相关系数分析，从高分波段中选取与目标波段最相关的波段作为输入，以提升光谱一致性。
2. 不依赖引导波段的图像重建：如 Bicubic 插值法，直接对低分辨率图像进行空间插值，既不使用高分波段信息，也不考虑光谱特性，属于零先验的图像增强方法。
3. 融合多个高分波段信息进行回归引导：如 Random Forest 与 ATPRK 方法，通过集成多个高分波段构建特征栈，建立从结构波段到目标波段的映射关系，在提升空间细节的同时兼顾光谱保真度。
4. 深度融合多源波段信息的端到端模型：如 DSen2 模型，综合使用高分、中分甚至低分波段信息，在网络结构中学习跨波段、多尺度的特征关系，实现更复杂场景下的超分辨率重建。

综上，不同的引导方式和融合策略直接影响超分结果的空间重建质量与光谱一致性。表 2 列出了本文所采用各类方法的引导波段配置。后续在第 3.3.1 节中，将详细介绍每一种方法的融合流程与实现过程。

3.3.1 传统方法

(1) 双三次插值 (Bicubic)

双三次插值是一种经典的图像重采样方法，在 Copernicus 提供的 Sentinel-2 L2A 产品处理接口中，Bicubic 被列为官方支持的重采样方法之一，可用于在用户请求不同分辨率（如 5m/px）影像时进行插值处理。在本研究中，为模拟低分辨率影像的超分重建过程，采用 cv2.INTER_CUBIC 算法将降采样至 40m 的影像逐波段上采样回 20m，并与原始 20m 图像进行定量对比分析。

(2) Brovey 变换

Brovey 融合方法是一种基于比例系数的图像增强算法，适用于融合多光谱与高分辨率可见光波段。本实验中将 40m 的低分辨率波段（B05 - B12）上采样至 20m 后，利用高分辨率波段 B2、B3、B4 构建总亮度信息 $I_{\{HR\}} = B_2 + B_3 + B_4$ ，并用其与上采样的 RGB 分量的合成亮度比值进行调节，实现空间细节增强，公

式如下：

$$I_{\{SR\}} = I_{\{up\}} \cdot \{I_{\{HR\}}\} / \{I_{\{LR\}} + \epsilon\} \quad (\text{式 3})$$

其中 $I_{\{up\}}$ 为上采样图像， ϵ 是为防止分母为零所加的极小量。

(3) PCA 主成分分析

PCA 是一种基于统计降维的图像融合方法，适用于提取图像的主要变化方向。在本研究的基准方法中，融合特征栈包括高分辨率波段 B2、B3、B4 及上采样后的低分辨率目标波段，通过 `sklearn.decomposition.PCA` 提取第一主成分 (PC1)，作为融合输出图像。该主成分在空间上继承了高分波段的结构特征，同时包含低分波段的光谱特征，实现了在保持光谱一致性的同时增强空间细节。PCA 的基本数学模型如下：

$$Z = XW \quad (\text{式 4})$$

其中 X 为原始像素向量， W 为特征向量矩阵， Z 为主成分投影。输出影像即为将 Z_1 重塑为二维图像后的结果。然而，如彭实[12]指出，PCA 方法在主成分替换阶段存在一定局限性，尤其在缺乏合适高分波段配合的情况下，可能导致融合图像出现光谱畸变或结构失真。为此，本文在基准 PCA 方法基础上引入了两种优化策略，旨在提升融合图像的光谱一致性与空间结构表现：

- **策略 1：** 基于 Pearson 相关系数分析，本文首先确定每个 20m 波段与 10m 波段之间最相关的一对波段组合（如 B5 与 B8，B6 与 B8 等），随后将该最相关的 10m 波段与上采样后的 20m 波段共同作为 PCA 输入，仅保留两个特征通道用于主成分提取。该策略参考了彭实关于“高光谱图像主成分替换引发光谱偏移”的分析，意在通过简化特征空间、突出波段间相关性，缓解主成分退化的问题。
- **策略 2（加权融合法）：** 本研究在保持原始 PCA 操作不变的前提下，进一步将提取出的第一主成分图像与最相关的 10m 引导波段进行线性加权叠加，即：

$$Z_{\text{fused}} = \alpha \cdot Z_1 + (1 - \alpha) \cdot I_{\text{corr}} \quad (\text{式 5})$$

其中 $\alpha = 0.7$ ， Z_1 为第一主成分图像， I_{corr} 为与当前 20m 波段相关性最高的 10m 波段图像。

这两种策略在融合前阶段充分利用了波段间的结构关系，并在方法逻辑上与后续 ATPRK 方法中所涉及的波段相关性分析部分形成互补，为整体模型的构建与方法选择提供了先导性基础。

(4) ATPRK 区域-点回归克里金融合方法

ATPRK (Area-to-Point Regression Kriging) 是一种将回归建模与地统计插值结合的超分辨率图像融合方法，适用于低分辨率遥感影像的空间细节重建与光谱保持优化任务。该方法在城市遥感和多光谱图像融合中被广泛应用，具备良好的理

论可解释性与空间一致性保障能力。

本研究的 ATPRK 是由 Wang 等人[13]开发设计, 其基本流程参考他们发表的论文内容, 分为两个核心部分 (回归建模与残差克里金插值):

1. **回归建模阶段**, 将低分辨率目标波段 (如 Sentinel-2 的 B05 - B12) 视为预测对象, 将高分辨率引导波段 (如 B2 - B4) 作为自变量, 构建像素级线性回归模型:

$$Z' C_l(x) = a_l Z_C(x) + b_l + R(x) \quad (\text{式 6})$$

其中 $Z' C_l(x)$ 表示第 1 个多光谱波段对应的模拟值, $Z_C(x)$ 表示 PAN 波段经点扩散函数 (PSF) 卷积后的图像, a_l 、 b_l 为回归系数, $R(x)$ 为残差项。

在实际操作中, 本研究通过高斯型 PSF 模拟传感器成像过程, 对 PAN 图像进行模糊卷积处理, 从而实现与中分辨率波段的空间匹配。使用最小二乘法估算 a_l 和 b_l , 进而在每个像素位置计算回归预测值:

$$\widehat{Z}_{F_l}(x_0) = a_l Z_F(x_0) + b_l \quad (\text{式 7})$$

2. **残差插值阶段**, 利用 Area-to-Point Kriging 方法对上述回归残差项进行高分辨率下的细节恢复。首先构造残差图像:

$$Z_{C_l}^r(x) = Z' C_l(x) - [\widehat{Z}_{F_l}(x_0) + b_l] \quad (\text{式 8})$$

然后建立从区域像素到点像素的克里金系统, 构造半变异函数 $\gamma_{CC}(x_i, x_j)$

与 $\gamma_{CF}(x_0, x_j)$, 通过试探 - 拟合过程确定变异函数的 sill 与 range 参数, 并解算克里金权重 λ_i , 从而实现细粒度残差项的空间插值:

$$\widehat{Z}^r F_l, 2(x_0) = \sum i = 1^N \lambda_i Z_{C_l}^r(x_i) \quad (\text{式 9})$$

3. **融合输出生成**, 将回归预测项与残差克里金项相加, 最终得到完整的超分辨率图像重建结果:

$$\hat{Z}F_l(x_0) = \widehat{Z}^r F_l(x_0) + \widehat{Z}_{F_l, 2}^r(x_0) \quad (\text{式 10})$$

与前面的方法相比, ATPRK 能够结合局部空间统计信息, 对区域内的纹理差异进行建模与恢复, 避免过度平滑或光谱失真问题, 尤其适用于城市纹理复杂、地物边界锐利的遥感场景。

在本研究中, ATPRK 实现于 MATLAB 环境下, 配合人工退化重建模拟生成的 40m - 20m 数据对, 在 Sentinel-2 图像样本上完成多波段的超分重建, 关键代码可见附录 A。

3.3.2 机器学习方法

随机森林（RF）是一种集成学习方法，由多个决策树组成，通过投票机制实现回归或分类任务。在超分辨率重建中，RF 能有效捕捉图像间复杂的非线性映射关系，已广泛应用于多光谱影像融合与降尺度预测任务中。

在本研究中，RF 模型用于从高分引导波段（B2、B3、B4）和低分波段上采样图像中预测原始 20m 波段的细节结构。具体流程如下：

（1）特征构建：对于每个待重建的 20m 波段，输入特征包含以下四个通道：

- 三个 10m 空间分辨率的高分波段：B2（蓝）、B3（绿）、B4（红）；
- 一个从当前 20m 波段降采样为 40m、再双三次插值上采样回 20m 的模拟图像（记为 I_{up} ），用于提供粗略的空间补偿结构。

形成 4 维像素特征向量：

$$X = [B2, B3, B4, I_{up}] \quad (\text{式 11})$$

作为回归模型的输入；对应的目标值 y 为当前 20m 波段原始像素值。

（2）样本采样与训练：为在保障模型准确性与训练效率间取得平衡，实验中采用随机采样方式从全图像素中选取约 5% 的像元作为训练数据。

采用 `sklearn.ensemble.RandomForestRegressor` 中的实现进行训练，设置：

- 树数量 $n_estimators = 50$
- 并行线程数 $n_jobs = -1$
- 固定随机种子 $random_state = 42$ 以保证重现性。

模型训练完成后，在全图范围内应用回归器进行逐像元预测，并将预测结果重塑为二维图像，即得到该波段的超分辨率重建结果。

（3）模型输出：重建图像进行像素值裁剪并转换为 `uint16` 类型后保存为 GeoTIFF 格式，保留空间参考信息，确保后续结果可用于空间对齐与时序对比。

3.3.3 深度学习方法

DSen2 (Deep Sentinel-2) 是由 Lanaras 等人[5]提出的深度卷积神经网络模型，专为 Sentinel-2 多分辨率影像的超分辨率重建任务设计。该模型的目标是将中低分辨率波段（20m 和 60m）统一重建至 10m，以构建完整的多光谱高分辨率数据立方体，增强地物表达能力并提升遥感影像在城市监测中的适用性。

与传统图像增强方法不同，DSen2 采用端到端的卷积神经网络结构（CNN），直接学习低分辨率波段与高分辨率输出之间的映射关系。该网络基于残差网络（ResNet）框架构建，融合了 skip connection 与多层次卷积结构，使其既能学习空间纹理的细节信息，又能保持图像的光谱一致性。模型将高分波段（B2、B3、B4、B8，10m）与待重建的中分波段（B5 – B12，20m）作为联合输入，输出目标分辨率下的图像。

为解决缺乏真实 Ground Truth 的问题，DSen2 提出了自监督模拟训练策略：将原始 20m 波段下采样为 40m，再训练网络从 40m 重建至 20m，与本文的方法性能对比验证策略同理。通过假设空间细节迁移具有尺度不变性（scale-invariance），模型训练在低尺度完成，而推理阶段可无缝迁移至 20→10m 任务。

训练过程中使用高斯模糊模拟传感器点扩散函数 (PSF)，下采样窗口为 2×2 ，实现了数据的合成真实化。

网络输入按波段分为三组：A = {B2, B3, B4, B8} (10m)、B = {B5 - B12} (20m)、C = {B1, B9} (60m)，分别对应三种空间分辨率。DSen2 实际由两个子网络构成：

- T2×：用于 $20m \rightarrow 10m$ 超分任务，输入为(yA, yB)，输出为重建后的xB；
- S6×：用于 $60m \rightarrow 10m$ 超分任务，输入为(yA, yB, yC)，输出为重建后的xC。

每个网络均先将低分辨率波段通过双线性插值提升至目标分辨率，再与高分辨率波段拼接输入网络。网络结构包括初始卷积层、多个 ResBlock 模块（每个模块含两个卷积层和一次 ReLU 非线性激活）以及最终卷积输出层，结合长距离残差连接，实现对高频细节的恢复与强化。

最终输出为：

$$x = \text{conv}_{\text{last}} + \text{bilinear-upsampled input} \quad (\text{式 12})$$

即网络实际学习的是插值图像与高分图像之间的残差值，这种“残差学习”策略能有效保持图像的光谱反射值，避免过拟合并提升重建效果。

本研究在调用原始 DSen2 模型时，参考作者公开 GitHub 仓库的实现方式，并结合自身实验设计对数据输入方式进行了调整与适配。原始模型输入依赖完整的 .SAFE 文件结构与 MTD_MSIL1C.xml 元数据进行图像读取与波段预处理，而本研究使用了自定义裁剪后的 TIFF 影像作为输入，配合人工退化重建模拟生成的 40m 与 20m 训练对，构建了更加灵活的实验环境。

为此，研究对脚本 s2_tiles_supres.py 进行了本地重写，实现对指定路径下裁剪图像的直接读取、区域处理与超分重建。模型部署于 Python + TensorFlow/Keras 环境中，使用原始 T2×网络预训练权重进行直接预测，无需重新训练。网络的核心参数配置如下：

- 残差模块数量：d = 6 (对应深层 DSen2 版本)
- 卷积通道数：f = 128
- 卷积核大小： 3×3
- 激活函数：ReLU
- 损失函数：L1 像素差 (Mean Absolute Error)
- 优化器：Adam + Nesterov 动量优化

所有图像均在块级 (tile-based) 方式下推理预测，避免大图超出 GPU 显存限制，并在边界处留有重叠区域以减轻缝隙伪影。

第四章 结果

实验结果将从定量和定性两方面进行展开讨论，同时包括细节性对比。

4.1 定量指标对比

为系统比较不同超分辨率重建方法的性能，本文从 PSNR、SSIM、SAM 和 RMSE 四个指标，对六种典型方法（Bicubic、Brovey、PCA、ATPRK、Random Forest、DSen2）在 Sentinel-2 的六个 20m 波段（B05 - B12）上进行全面评估。实验区域为北京市内 600×600 尺寸的城市核心区块，该区域混合了密集建筑、水体、植被与道路等多类地物，为验证各方法的泛化性能与光谱结构还原能力提供了理想测试场景。纵览结果如表 3 所示。

表 3 方法定量结果总览

SR Method	Band	PSNR	SSIM	SAM	RMSE
Bicubic	B05	35.76	0.9071	3.96	204.32
	B06	32.98	0.8729	3.33	211.46
	B07	32.54	0.8668	3.50	237.71
	B08	31.68	0.8652	3.38	238.93
	B11	38.21	0.9425	2.52	167.82
	B12	35.13	0.9190	3.30	191.51
Brovey	B05	38.72	0.9559	2.82	145.33
	B06	30.18	0.7707	4.60	291.97
	B07	29.22	0.7412	5.12	348.12
	B08	28.04	0.7191	5.14	362.98
	B11	35.21	0.8920	3.57	237.21
	B12	35.06	0.9234	3.33	193.14
PCA (原始)	B05	19.47	0.5229	14.26	1371.39
	B06	14.36	0.4378	37.94	2290.91
	B07	13.20	0.4201	39.94	2490.15
	B08	12.99	0.4033	40.33	2651.59
	B11	17.36	0.4479	33.96	2292.84
	B12	17.05	0.4830	29.36	1728.51
ATPRK	B05	35.87	0.9507	1.57	160.94
	B06	35.23	0.9444	1.57	173.10
	B07	34.10	0.9432	1.57	197.18
	B08	33.90	0.9439	1.57	201.88
	B11	34.97	0.9351	1.57	178.42
	B12	34.20	0.9366	1.57	195.08
Random Forest	B05	42.15	0.9807	1.90	97.86
	B06	34.52	0.9133	2.79	177.09
	B07	33.66	0.9014	3.07	208.85
	B08	32.71	0.8955	3.01	212.18
	B11	39.24	0.9574	2.24	149.09
	B12	36.93	0.9538	2.68	155.60

DSen2	B05	39.03	0.9652	1.5692	111.88
	B06	41.72	0.9814	1.5692	82.01
	B07	41.84	0.9846	1.5692	80.87
	B08	42.33	0.9872	1.5692	76.51
	B11	40.87	0.9769	1.5692	90.49
	B12	39.84	0.9745	1.5692	101.88

在所有传统方法中，ATPRK 表现最为突出。其在所有波段的 PSNR 均稳定在 33 - 36 dB 之间，SSIM 高于 0.93，SAM 被控制在 1.57° 的极小值水平，RMSE 也维持在 160 - 200 以内，全面优于 Bicubic、Brovey 与 PCA 方法。其中，B05 - B07 波段为植被与边界敏感波段，ATPRK 能有效避免空间模糊与光谱漂移，而在 B11 - B12 热红外波段上，其空间细节恢复能力同样优异，验证了方法对不同波段的适应性。

相比之下，Brovey 方法虽在 SSIM 上接近或略高于 ATPRK，但其 SAM 与 RMSE 明显波动，尤其在 B07 - B08 上出现高达 5° 以上的光谱夹角误差，说明其在城市纹理复杂区域存在结构扭曲问题。PCA（原始形式）表现最差，不仅 PSNR 均低于 20dB，且 SAM 值普遍超过 30°，显示出该方法在未进行特征引导优化时容易丢失光谱特征。

在引入机器学习与深度学习方法后，DSen2 模型整体性能最强。其在所有指标上均表现极为出色：平均 PSNR 超过 40 dB，SSIM 接近 0.99，SAM 被控制在 1.5692° 以下，且 RMSE 在所有波段上普遍低于 100。该结果验证了深度残差网络在复杂非线性特征建模方面的强大能力。

随机森林（RF）作为机器学习方法，表现也较为优异。其在高频结构明显的 B05 - B07 上达到 33 - 42dB 的 PSNR，但在热红外波段（B11 - B12）上仍略逊于 ATPRK，且整体 RMSE 高于 ATPRK。值得注意的是，ATPRK 方法在不依赖任何训练集的前提下，在 B11 与 B12 波段的 RMSE 分别为 178 与 195，优于 RF 的 149 与 155 表现，仅略逊于深度学习 DSen2 的 90 与 101，显示出其在中高频谱段的强大光谱一致性建模能力。

从整体角度看，DSen2 确实展现出最强的空间恢复与光谱保真能力，适合在具备算力基础时应用于大规模多期遥感影像重建。而在训练资源受限或对计算效率要求较高的实际场景中，ATPRK 凭借其无需训练、理论稳健、光谱一致性强等特点，可作为优选方案备选使用。

4. 1. 1 单波段讨论（以 B05 波段为例）

为进一步探究各类方法在单一波段下的表现差异，本文选取植被敏感波段 B05 (705nm, 红边波段) 作为代表进行深入分析（结果如表 4）。该波段常用于植被红边指数（RENDVI）、叶绿素含量估算等精细化应用，对空间细节与光谱保持提出较高要求。

表 4 B05 波段各方法下的输出结果

B05	PSNR	SSIM	SAM	RMSE
Bicubic	35.76	0.9071	3.96	204.32
Brovey	38.72	0.9559	2.82	145.33
PCA	19.47	0.5229	14.26	1371.39
ATPRK	35.87	0.9507	1.57	160.94
Random Forest	42.15	0.9807	1.90	97.86

DSen2	39.03	0.9652	1.5692	111.88
-------	-------	--------	--------	--------

从定量结果来看，PCA 方法在 B05 上的表现最弱，表明 PCA 在未进行相关性筛选与引导优化时，易造成主成分信息偏离原始光谱结构，导致严重的光谱失真和空间细节缺失。Bicubic 与 Brovey 方法在空间细节还原方面稍有提升，但光谱角偏移仍较大。Brovey 虽能增强高频纹理，但因比例系数构造机制简单，难以保证光谱一致性，RMSE 为 145.33。

在此基础上，ATPRK 显著提升了光谱还原精度。该方法在 B05 上实现了 SSIM=0.9507、SAM=1.57° 的优秀表现。值得注意的是，ATPRK 的 PSNR 与 Bicubic 基本持平（35.87 和 35.76），但 SAM 显著下降 2.4°，说明其在空间质量未提升的情况下，极大优化了光谱角度，具备更强的光谱保真能力。

Random Forest 表现最为平衡，PSNR 达到 42.15 dB，为所有方法中最高；同时，SSIM 达 0.9807，SAM 控制在 1.90°，RMSE 降至 97.86，说明机器学习方法在回归拟合高频细节方面具有显著优势。然而，其光谱一致性略逊于 DSen2 与 ATPRK，说明其空间增强过程中仍存在一定程度的“重构”偏移。

DSen2 作为最优方法综合表现最佳。虽然 PSNR (39.03) 略低于 RF，但 SSIM 高达 0.9652，SAM 达到 1.5692，为所有方法中最低值，且 RMSE 控制在 111.88，综合空间与光谱指标均处于最优区间。该模型通过残差学习策略有效抑制了重建误差，同时兼顾了空间纹理与光谱响应的统一，尤其在 B05 等敏感波段中展现出卓越的重建能力。该结果从侧面印证了深度学习与空间统计方法在此类波段中的融合优势。

4.1.2 多波段指标稳定性分析

在多波段超分辨率重建任务中，不仅需要考虑单一波段的重建质量，还应关注模型在不同波段之间的性能稳定性，即算法在不同光谱响应、地物复杂性下的一致性表现。为此，本文进一步对比分析了 ATPRK、Random Forest (RF) 与 DSen2 三种方法在 PSNR、SSIM、SAM 和 RMSE 四项指标上的波段间波动特征，探讨其在多光谱超分中的泛化能力与鲁棒性。

从整体趋势来看，Random Forest 在部分波段表现出色，例如在 B05 波段上取得了 PSNR=42.15、SSIM=0.9807、RMSE=97.86 的最佳表现。然而，其在 B06 - B08 等波段的表现波动较大，如 B06 的 RMSE 上升至 177.09，B08 的 SAM 超过 3.0°，说明模型的预测精度受限于训练样本的波段特征覆盖能力，在不同波段间难以保持一致性。

相较之下，ATPRK 表现出更高的指标稳定性。在 B05 - B12 的所有目标波段中，其 PSNR 始终保持在 33.90 - 35.87 之间，SSIM 稳定在 0.935 - 0.951，SAM 近似恒定在 1.57°，RMSE 也控制在 160 - 200 范围内。这种稳定表现得益于其结合了全图区域的空间协方差建模和点级残差插值能力，不依赖训练样本，能较好地适应不同光谱响应下的空间重建任务。

DSen2 在所有方法中最具稳定性与高性能兼备的优势。无论是 PSNR (39.03 - 42.33)，SSIM (0.9652 - 0.9872)，还是 SAM (全部为 1.5692) 和 RMSE (最低至 76.51，最高不超过 111.88)，DSen2 的每项指标均保持在高度集中、理想的数值范围内。这表明其深度卷积架构不仅有效捕捉了低分辨率波段中的高频纹理信息，还在网络层次上实现了不同波段间的协同特征提取与重建，具有极强的泛化能力。

下图是基于 SSIM 数据得到的折线图。图三可以清晰的看出：DSen2 在所有波段上表现稳定且整体最高，说明其在结构保持方面具有强大的一致性；Random

Forest 虽在部分波段表现出色，但整体波动较大；ATPRK 则介于两者之间，整体稳定、差异小。

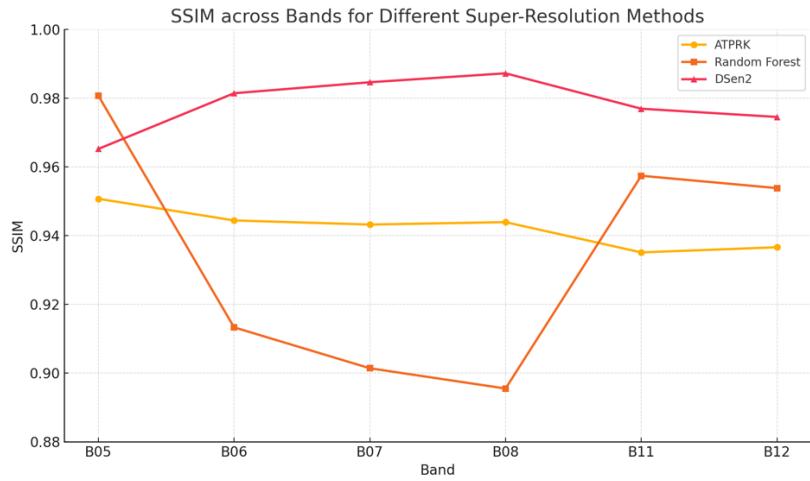


图 3 三个相对最优方法的 SSIM 指标结果对比

4. 1. 3 PCA 潜能以及波段相关度展示

PCA 方法应用了两个简单优化，基于波段相关性计算的结果（如表 5）。

表 5 20m 波段和 10m 波段的相关度结果一览

	B2	B3	B4	B8
B5	-0.0637	-0.0633	-0.0643	-0.0155
B6	-0.0095	-0.0076	-0.0111	0.0114
B7	0.0091	0.0113	0.0073	0.0179
B8a	0.0169	0.0188	0.0147	0.0182
B11	-0.0577	-0.0611	-0.0634	-0.0286
B12	-0.0809	-0.0839	-0.085	-0.0296

可知每个待超分波段最相关的 10m 波段的关系：B7 与 B3 最相关，剩余波段均和 B08 最相关。根据两个优化策略分别进行处理后获得如下结果（表 6-8）：

表 6 优化前的 PCA 超分结果

Band	PSNR	SSIM	SAM	RMSE
Band5	15.47	0.5229	39.26	1371.39
Band6	14.36	0.4378	37.94	2209.91
Band7	14.20	0.4201	39.58	2490.15
Band8	11.99	0.4033	30.33	2651.59
Band11	17.36	0.4479	33.96	2292.84
Band12	17.05	0.4830	29.36	1728.51

表 7 方案一优化后结果

Band	PSNR	SSIM	SAM	RMSE
Band5	18.58	0.4224	32.32	1625.41
Band6	15.10	0.4290	33.00	2305.26
Band7	15.08	0.4298	32.41	2537.76
Band8	12.65	0.4763	31.41	2798.21
Band11	17.89	0.4112	20.95	2474.55
Band12	17.43	0.4343	27.19	1930.21

表 8 方案二优化后结果

Band	PSNR	SSIM	SAM	RMSE
Band5	23.07	0.7529	6.94	757.52
Band6	17.89	0.8296	6.32	1398.03
Band7	17.64	0.8241	6.42	1635.83
Band8	15.76	0.4878	19.44	2342.27
Band11	21.46	0.7213	5.34	1586.27
Band12	21.41	0.8538	5.68	1080.71

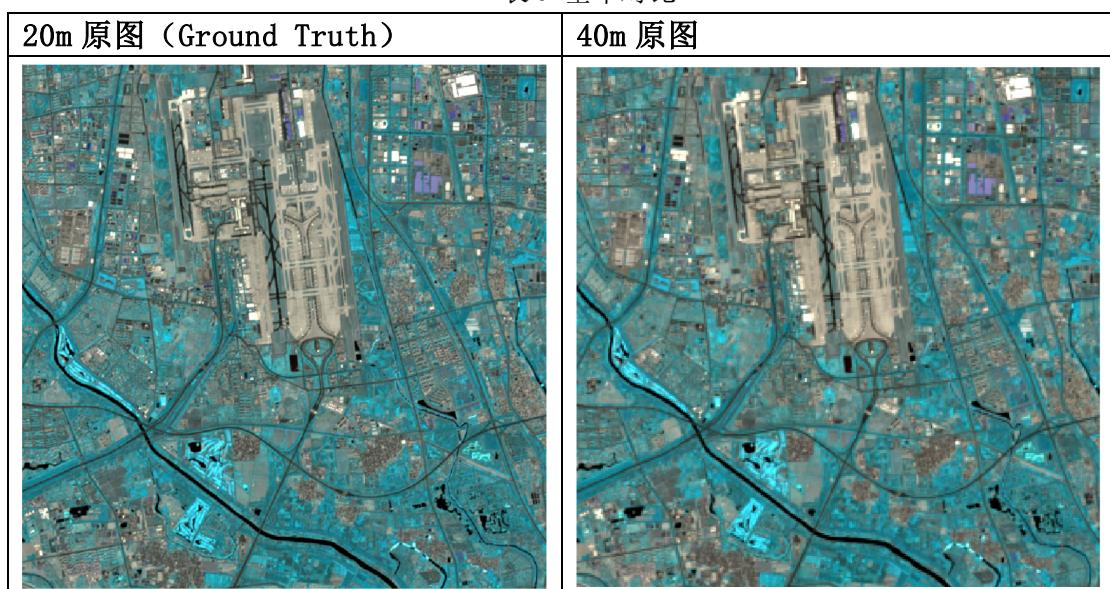
从结果来看，PCA 在经过最相关波段引导与加权融合策略（方案二）后有一些提升，在多数波段上表现优于原始方法，尤其是光谱特性（SAM）和结构相似性（SSIM）。这表明，在合理选取主成分或引入结构引导波段后，该方法具有潜在的优化空间，但仍难以达到高水准。该部分将在“讨论”章节中进一步展开。

4.2 可视化对比

为进一步验证各超分辨率方法在城市复杂地物条件下的表现，本文测试区域构建假彩色合成图进行视觉评估。假彩色图使用如下波段组合：R(B05)、G(B06)、B(B07)，以增强建筑、水体、道路等要素的判读效果。原图参考包括：原始 20m 分辨率图像，作为 Ground Truth (GT) 及降采样后未经超分的 40m 影像。

展示出来的典型超分重建方法包括 Bicubic 插值（传统基准方法）、Random Forest（机器学习方法）、ATPRK（地统计建模方法）与 DSen2（深度学习方法）。在统一视图中（图四，五，六），四种方法的可视化结果以 2×2 布局呈现，其中：左上为 Random Forest、右上为 Bicubic 插值、左下为 DSen2、右下为 ATPRK，便于细节间横向对比。

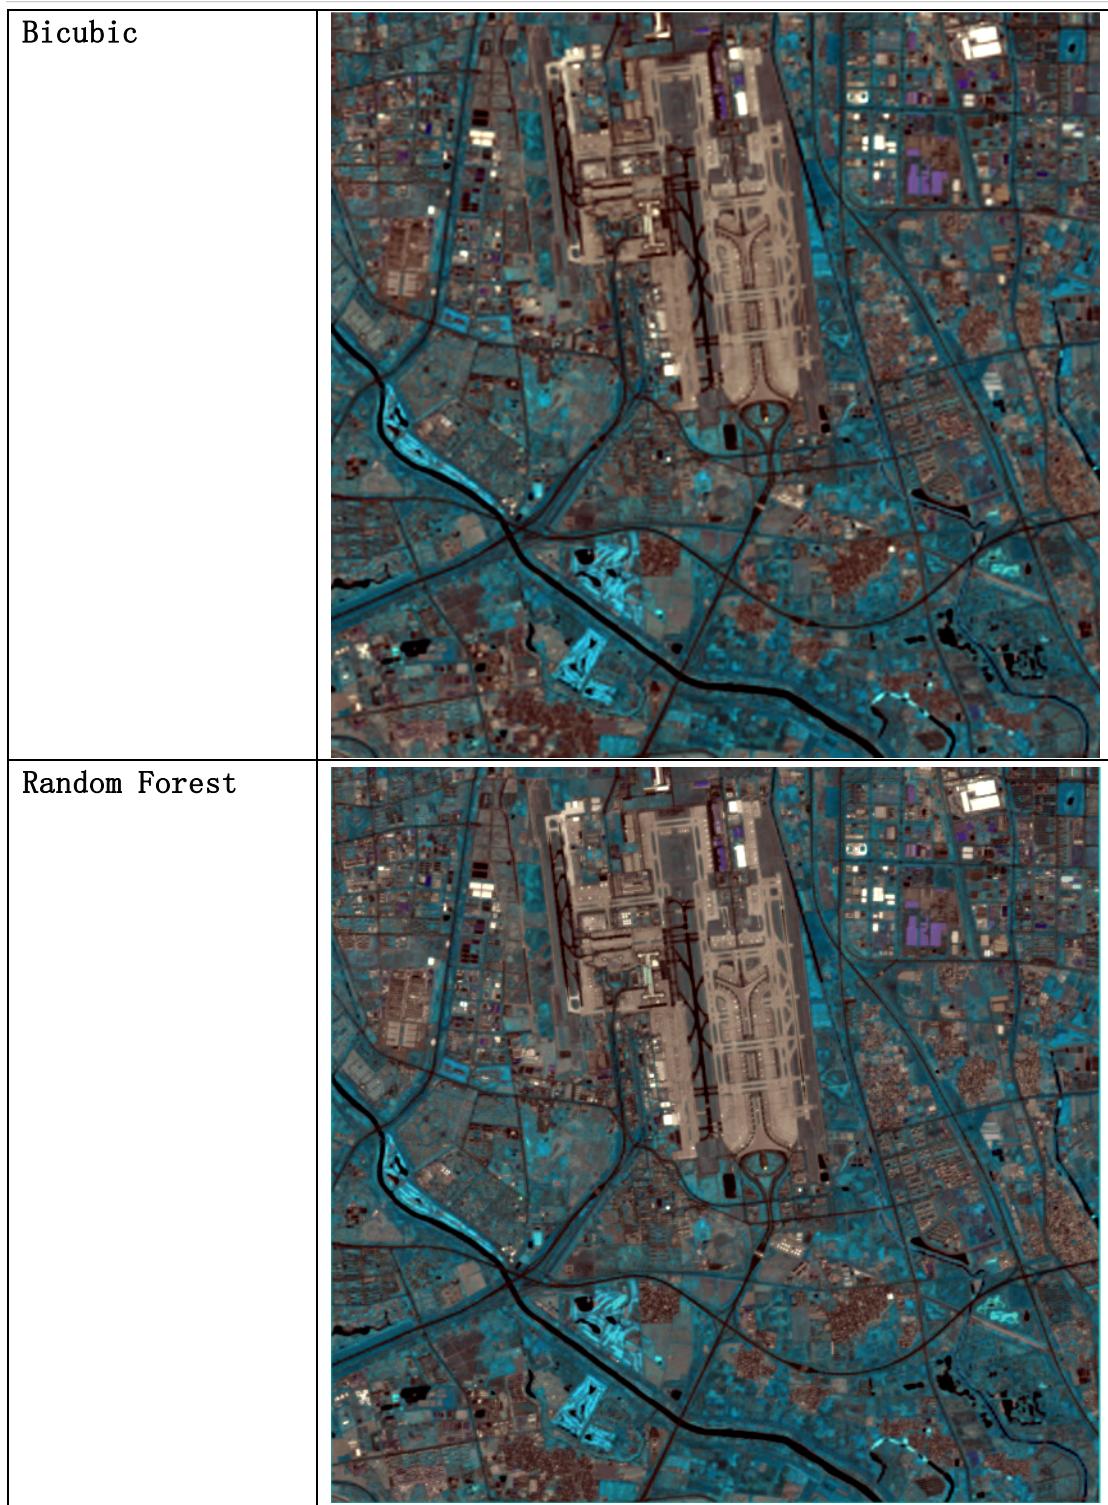
表 9 基本对比

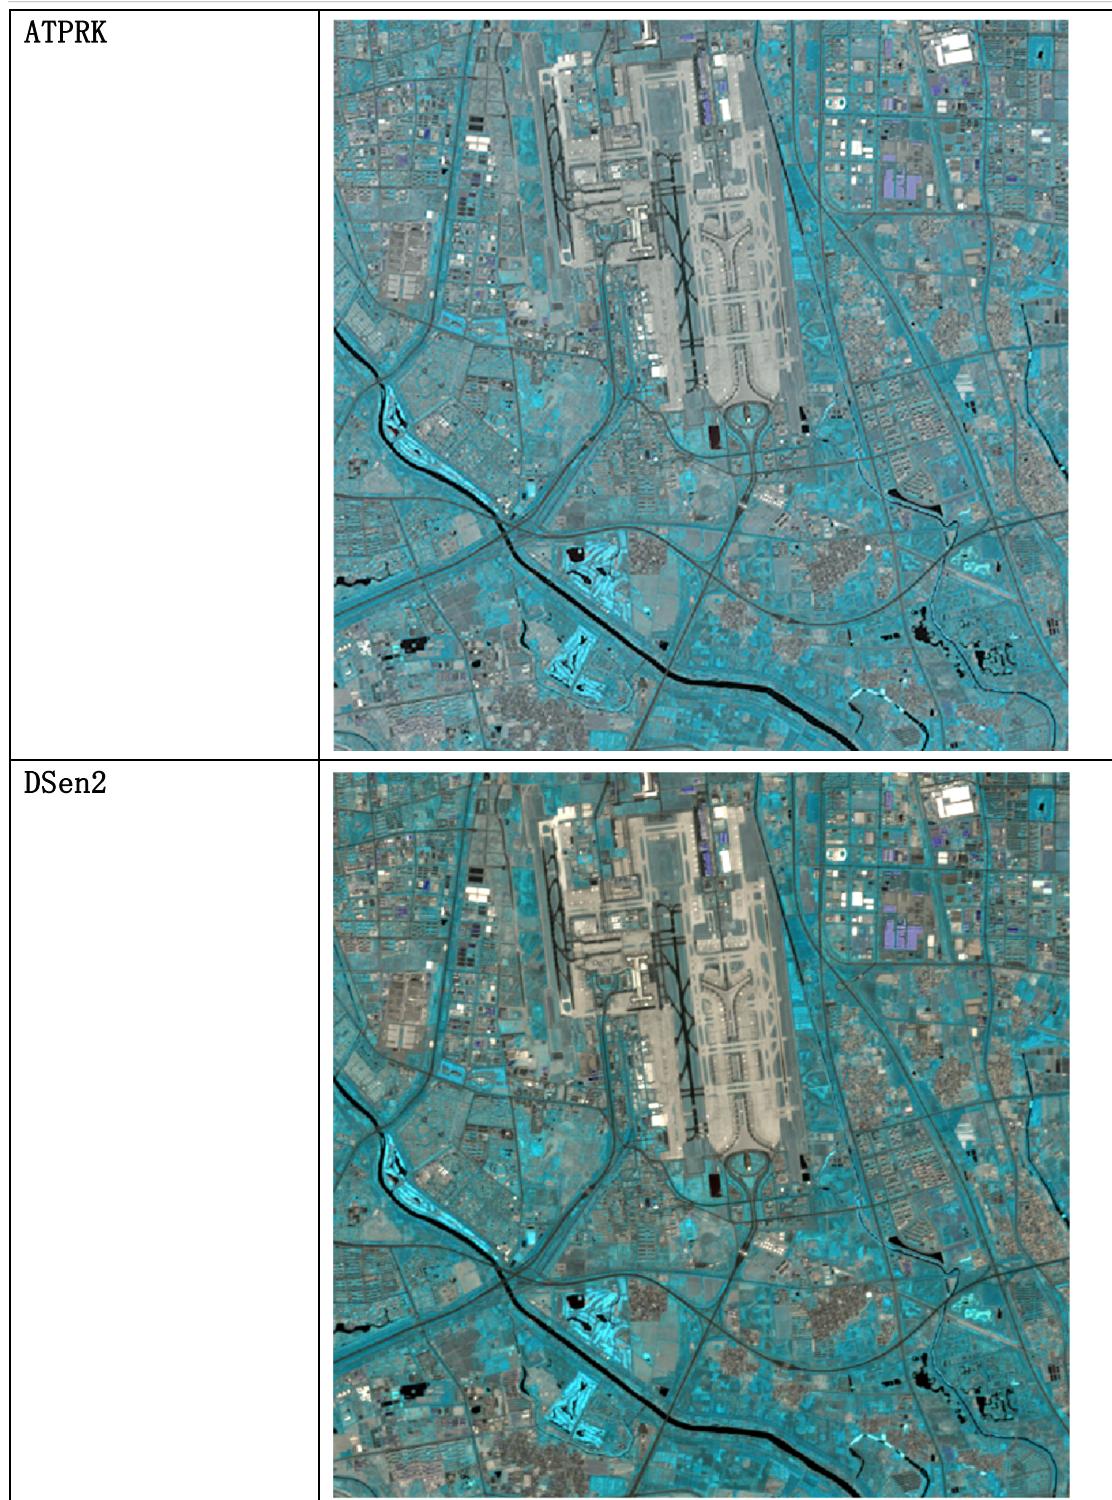


左侧为 20m 波段下呈现出来的原图，用于对比超分后的效果。右侧是 40m 超分前的图像，用于验证各个方法都一定程度上使图片更加清晰，还原了细节。

表 10 各方法超分后的视觉总览

方法	结果图
----	-----





肉眼可见，无论是清晰度还是色彩还原度来看，ATPRK 和 DSen2 都比较优秀。下面将对比细节性地标，进一步探究不同方法的优缺点。

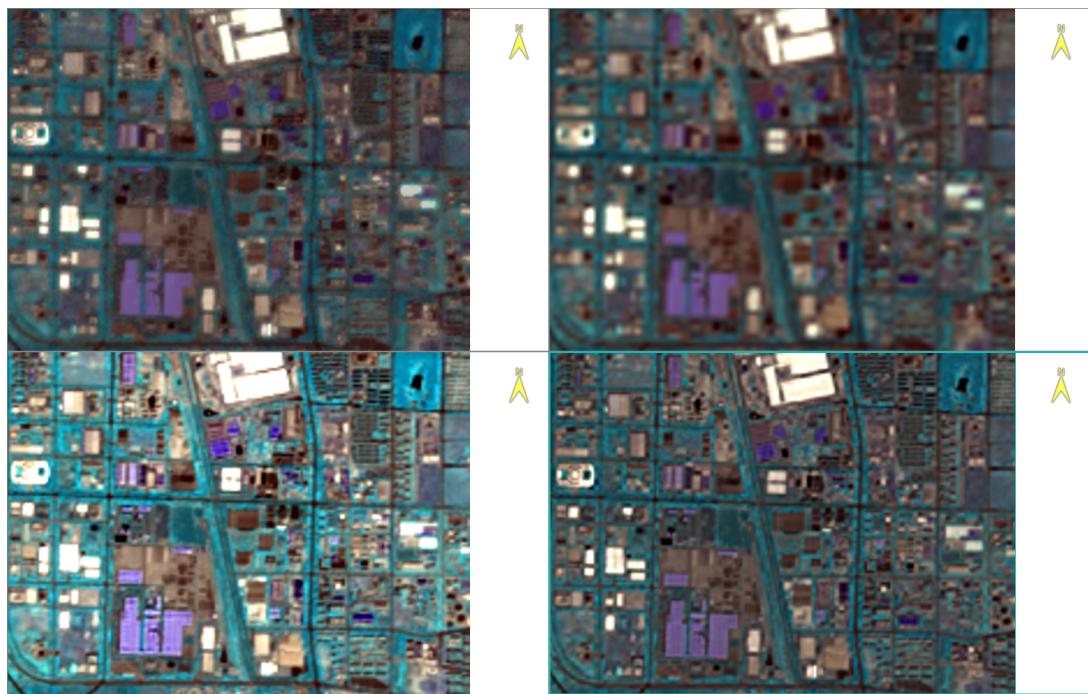


图4 细节一展示：东北角建筑群

Bicubic 插值法（右上）虽然作为基线方法提供了大致结构轮廓，但图像模糊、边缘不清，细节纹理明显缺失，无法有效辨别建筑轮廓。Random Forest（左上）在某些区域表现出较强的纹理增强能力，部分建筑结构清晰可见，如正北方白色矩形建筑，明显比右上图插值法的纹理清晰，但也出现了边界过锐或局部伪影现象，整体稳定性略逊。相比之下，ATPRK 方法（右下）在保持光谱一致性的同时，恢复了较好的建筑边缘与形状，细节表现稳定，纹理自然。DSen2 方法（左下）综合效果最佳，不仅建筑边界锐利清晰，且空间结构连贯，纹理丰富，基本还原了地物真实形态，显示出其在细节重建方面的强大优势。

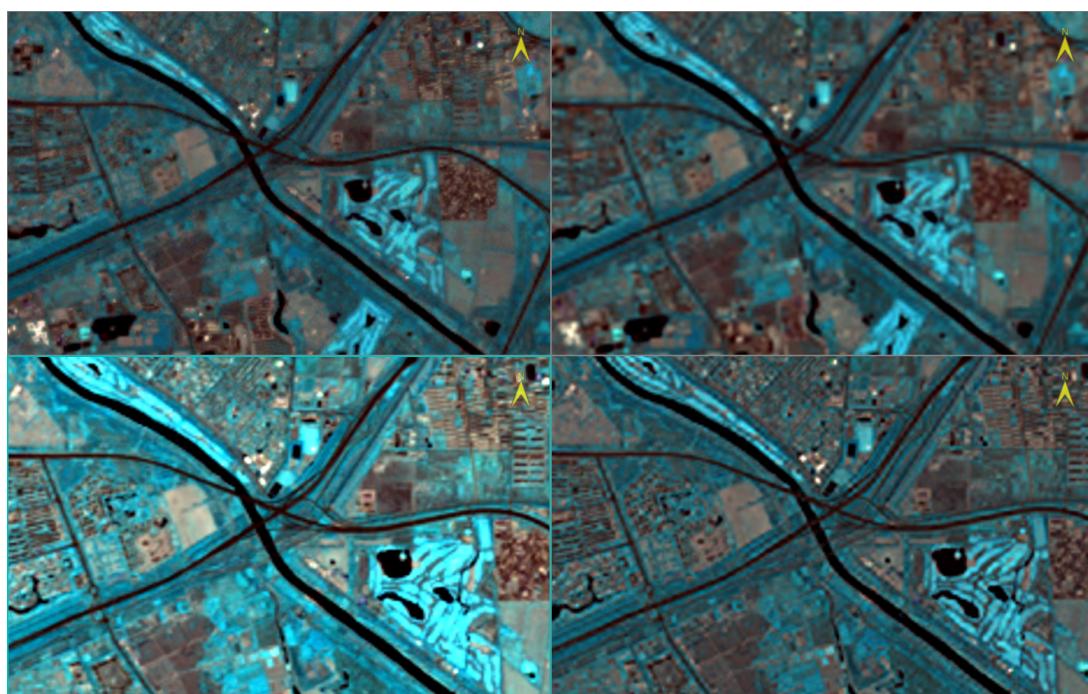


图5 细节二展示：水体与街道

与建筑群的呈现效果基本相仿，水体展现上，Bicubic 方法（右上）仍显模糊，街道边缘与河流轮廓不清。Random Forest（左上）虽然在水体边界方面较清晰，但部分街道和建筑存在虚化。ATPRK 方法（右下）和 DSen2 方法（左下）在街道网络结构的连续性与水体轮廓的保持上表现更佳，黑色道路主干线清晰完整，蓝色水体边缘平滑自然。

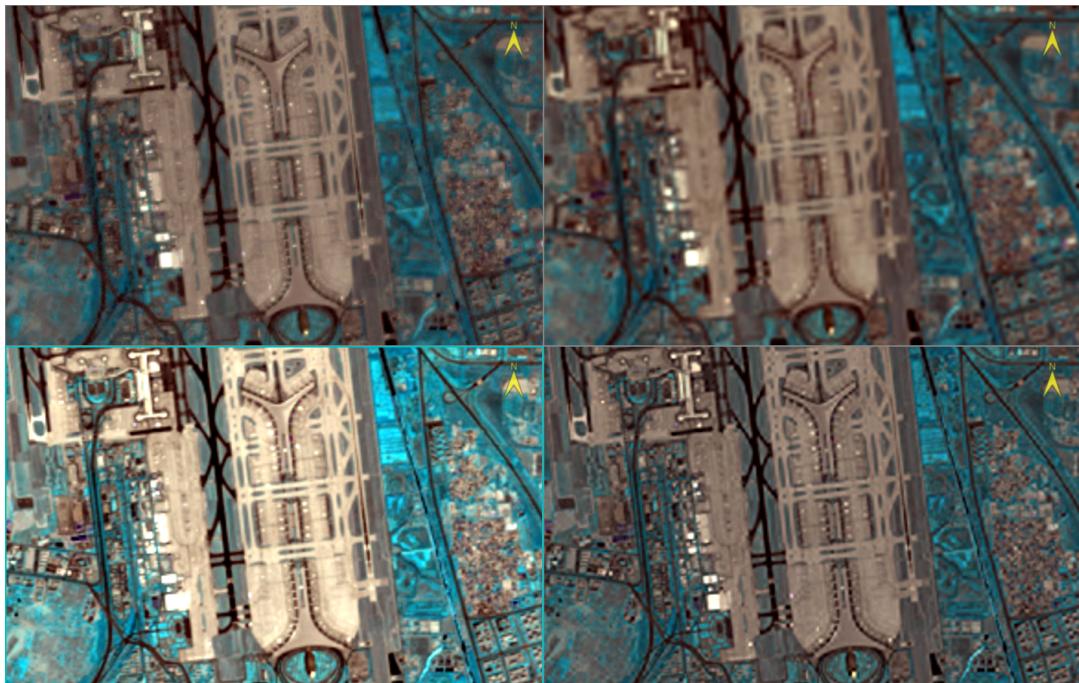


图 6 细节三展示：复杂建筑

在航站楼“Y”字结构的重建效果中，Bicubic 方法（右上）表现最为模糊，航站楼轮廓边缘较为松散，内部结构细节几乎无法识别。Random Forest 方法（左上）在边缘轮廓刻画上有所改善，但由于其随机性与模型拟合不均的特性，局部建筑边界不够连贯。ATPRK 方法（右下）则显著改善了细节保留效果，Y 形跑道边缘连续、纹理清晰，周围地物也较为真实自然。DSen2 方法（左下）在细节结构表达上进一步提升，不仅保持了 Y 字构造的清晰性，还增强了光谱一致性，呈现出更真实的建筑纹理，图像整体锐利且无明显伪影。

4.3 光谱一致性分析

为了进一步验证各超分方法在特定城市地物上的光谱还原能力，本研究在 ENVI 软件中选取了六种典型地物 ROI：植被、水体、建筑、道路、以及两种混合地物：水体与河岸交界、居民区（建筑与绿地）。

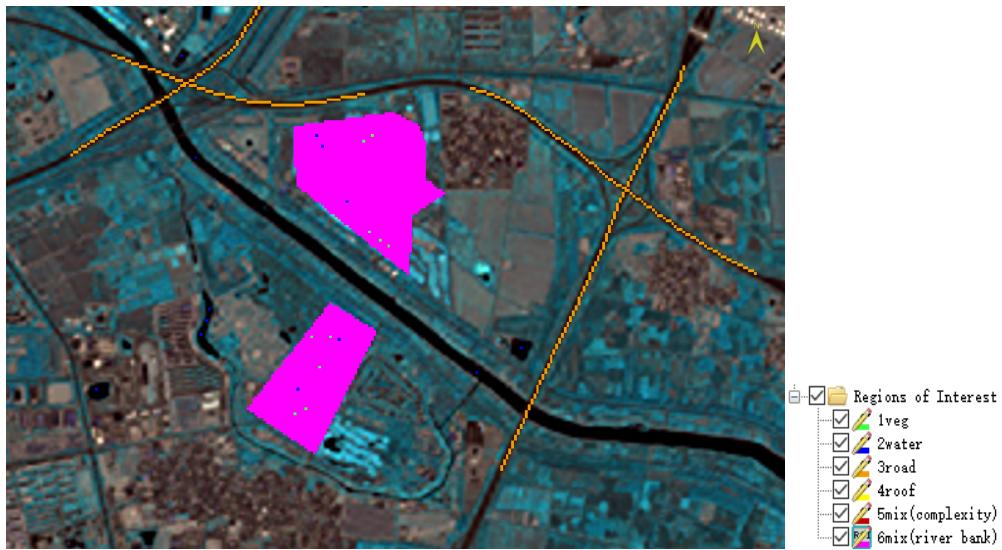


图 7 部分 ROI 选取的示意图 1

如图七所示，粉色部分代表水体与堤岸交界的区域。其上方的绿色和蓝色的选点分别代表植被和水体。橙色为桥和道路。



图 8 部分 ROI 选取的示意图 2

如图八所示，黄色代表居民楼或航站楼楼顶，红色代表复杂建筑群，以此处的居民区为例。

图九展示了四类典型单一地物（植被、水体、道路、建筑屋顶）在不同方法超分后的B05-B12波段上的光谱还原对比。折线图中，红色线代表原始20m分辨率图像（Ground Truth），其余曲线分别对应DSen2（蓝）、ATPRK（橙）、Random Forest（黄）与Bicubic插值（灰）重建结果的平均光谱值。曲线形态与地面真值的接近程度反映了不同超分方法的光谱保真能力。

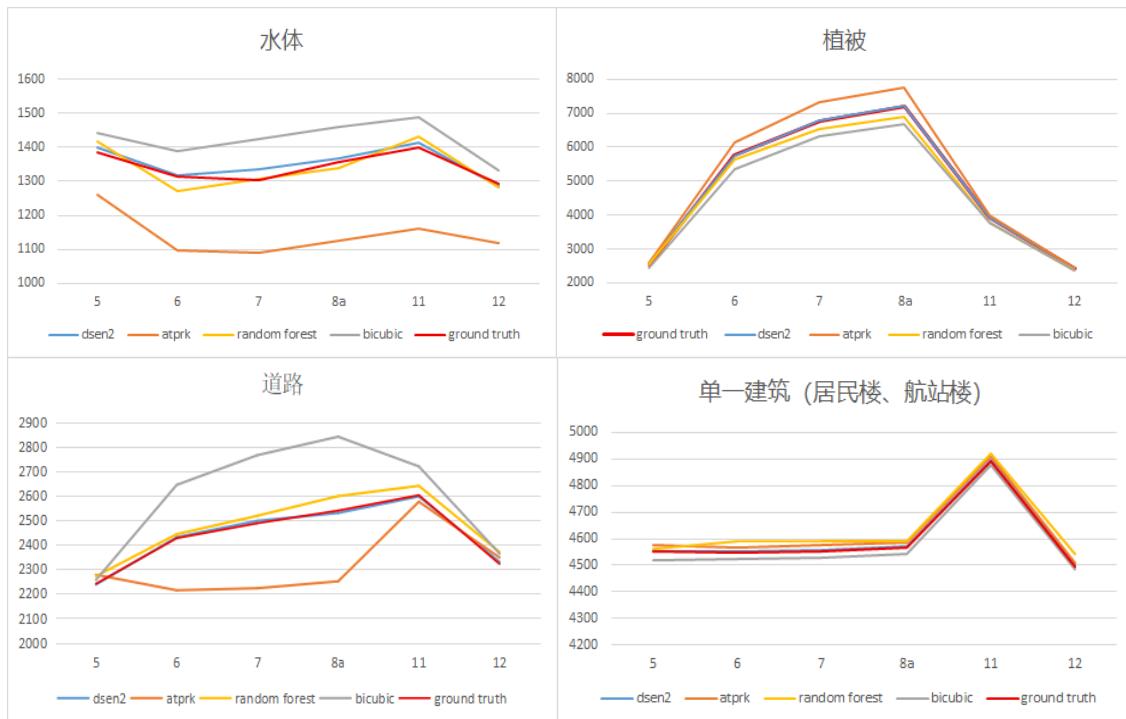


图 9 各方法在单一类型 ROI 的光谱曲线对比图组

在植被区域中，DSen2 重建曲线与 GT 最为接近，表现出较强的光谱一致性；Random Forest 整体略低，但趋势吻合；Bicubic 整体偏低，纹理还原欠佳；ATPRK 整体偏高，尤其在 B05 – B07 波段，说明其在强纹理地物中可能存在过拟合现象。

对于水体区域，DSen2 同样表现最优，重建曲线高度贴近 GT；RF 方法的总体趋势亦较一致，但各波段呈现不均衡偏差；ATPRK 整体偏低，但曲线形态与 GT 高度相似，表现稳定；而 Bicubic 在水体的表现最差，光谱走向与 GT 不一致，存在过度平滑问题。

在道路区域中，DSen2 的重建曲线基本贴合 GT，保持了较高的细节辨识度与光谱准确性；RF 次之，尽管整体还原效果良好，但某些波段略有偏差；ATPRK 在 B05、B11、B12 波段还原效果较佳，但在 B06 – B08A 明显偏低，说明其对线性结构的建模存在一定不足；Bicubic 呈现出与 ATPRK 相反的偏差趋势，B06 – B08A 波段显著高于 GT，表现出典型的光谱失真。

在建筑屋顶区域，各方法的表现差异较小，四种超分结果均能较好还原 GT 光谱特性。

图十的折线图组展示的是另外两种混合地物，分别为建筑群和河岸植被交界带，解释了不同方法对边界地物的还原能力。

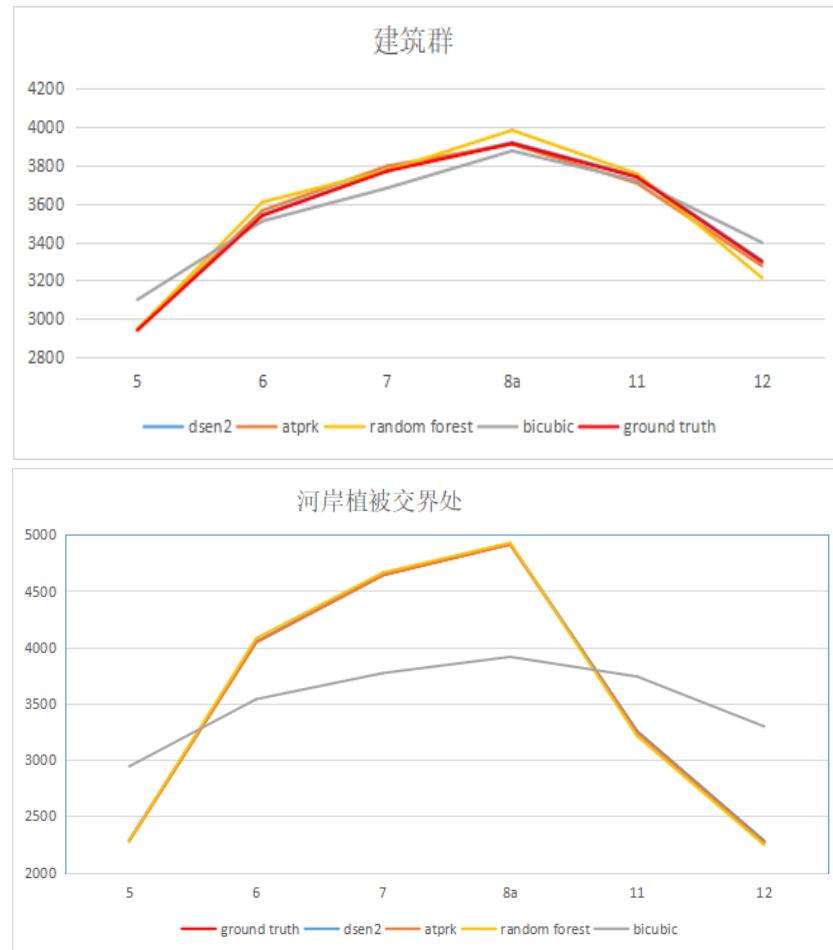


图 10 各方法在混合地物类型 ROI 的光谱曲线对比图组

建筑群区域中，DSen2 和 ATPRK 方法在各个波段表现出极高的还原精度，与 GT 光谱曲线重合度很高；RF 和 Bicubic 曲线均存在一定波动性和偏离。在河岸交界区域，除 Bicubic 方法外，其余三种方法在大多数波段上的光谱曲线均接近 GT。

4.4 方法优劣总结

在本研究的定量评估中，深度学习模型 DSen2 在 PSNR、SSIM、SAM 与 RMSE 四个指标上表现最为稳定且优秀，尤其在各个波段间展现出极高的一致性。而在定性分析中，无论是建筑边界、街道纹理还是水体结构，DSen2 的细节还原效果也明显优于其他方法。相比之下，另外几个也很优秀的方法如 Random Forest，尽管在部分波段指标上表现突出，但整体波动性较大；ATPRK 方法虽空间一致性强、结构还原良好，在城市遥感研究中广受推崇，但在本研究的小尺度城市区域中，DSen2 在视觉与光谱一致性上展现出更微妙的优势。

尽管已有研究指出在大区域或复杂地貌中，ATPRK 以其高效性与光谱保持能力优于部分深度学习方法，但本研究选取的是较小面积的城市典型区域，建筑密集、结构丰富，数据体量较小，使得深度网络的计算成本问题不再显著。因此，综合定量与定性表现，最终选用 DSen2 作为最优超分方法。

4.5 城市时序变化应用分析

为验证超分方法在实际遥感应用中的有效性，本文进一步以北京市亦庄-朝

阳区域为研究对象，基于 DSen2 网络生成的 10m 分辨率统一波段数据，开展了 2017 – 2024 年的城市生态变化分析。该区域位于北京市东南部，是近年来城市快速发展的重点区域，产业园区密集、建设活动频繁，具备较强的典型性。

在城市生态监测方面，本文提取了每年 6 月份云量控制在 10% 以下的 Sentinel-2 影像，构建了简化生态指数（RSEI）和不透水指数（ENDISI），分别用于衡量区域的生态质量与城市化强度（如表 11 所示）。从 5 年的时序结果来看，生态指数整体在 0.55 – 0.59 之间波动，其中 2024 年的平均生态指数为 0.5909，略高于 2017 年的 0.5830，显示出区域生态状态整体保持稳定，甚至有小幅改善趋势。尽管 2019 年的生态指数略有下降（0.5600），同时波动性也显著增大（ $\text{StdDev} = 0.344$ ），可能与当年建设活动集中或植被覆盖减少有关，需结合土地利用数据进一步分析。

ENDISI 作为更敏感的不透水面提取指标，在研究期间呈现出一定的阶段性增长趋势。2017 年的平均 ENDISI 为 0.396，到 2024 年已升至 0.545，反映出区域内不透水面覆盖比例显著增加，表征了快速城市化进程。尤其是在 2019 和 2023 年两个节点，ENDISI 分别达到 0.577 和 0.534，明显高于其他年份，显示出城市扩张活动的阶段性波动。不透水层面积也随之显著扩大，从 2017 年的 83.8 km² 增长至 2024 年的 147.6 km²，增幅接近 76%。其中，2019 年和 2023 年分别达到 161.2 km² 和 142.9 km²，说明这两年内存在明显的城市扩张高潮期，可能与基础设施建设、住宅用地扩展等有关，值得在未来研究中进一步探讨其驱动机制与生态影响。

表 11 各年份指数一览

年份	生态指数	生态指数方差	ENDISI（均值）	不透水层面积（km ² ）
2017	0.5830	0.187	0.396	83.8
2019	0.5600	0.344	0.577	161.2
2022	0.5535	0.247	0.432	99.3
2023	0.5608	0.252	0.534	142.9
2024	0.5909	0.247	0.545	147.6

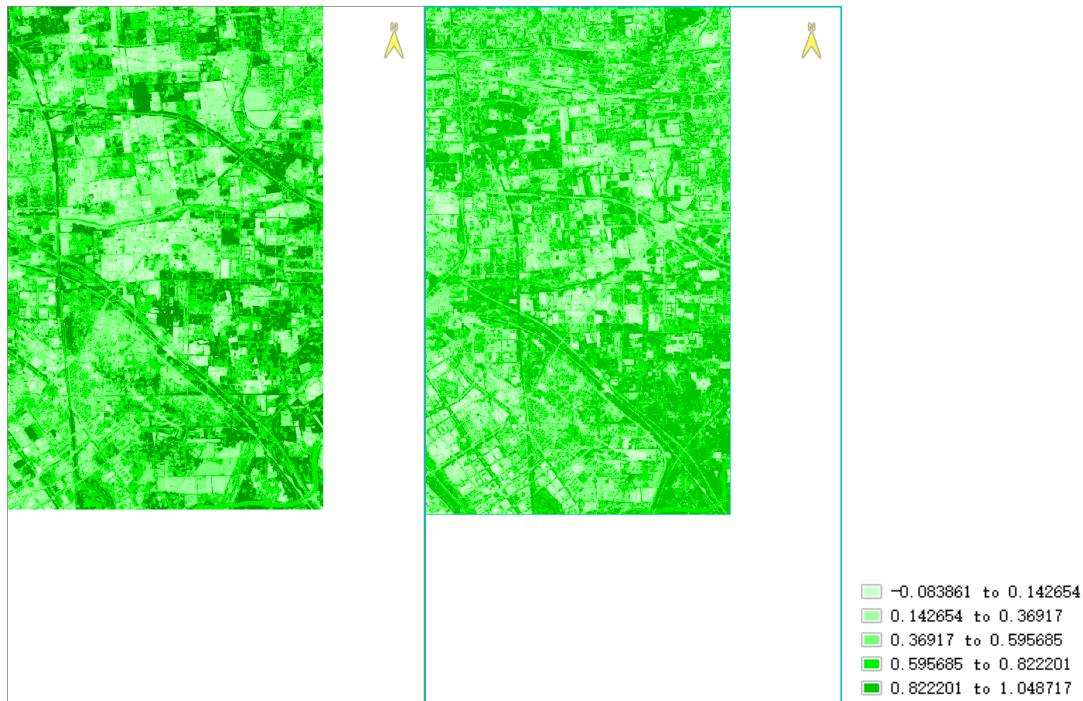


图 11 2024 年和 2022 年生态指数分布对比

图十一展示了生态指数分布最高（2024 年，左）与最低（2022 年，右）两个年份的空间分布图，绿色越深表示生态状况越优。为了更清晰呈现差异，图像进行了分级分类处理，将生态指数划分为五个等级区间，以揭示细粒度变化特征。从图中可以直观观察到，2024 年图像中高生态值区域（深绿色）在整体上更为密集且分布连续，尤其在南部与西南方向的农业区、绿地边界地带表现明显，说明该年绿化覆盖状况较好，生态环境恢复能力较强。

相比之下，2022 年图像中浅绿色与灰白区域较多，尤其是图像北部与中部区域，显示出较大范围的生态退化带，可能与城市建设强度提升、基础设施扩张有关。这也对应了该年 RSEI 平均值最低（0.5535）与波动性较大的现象（ $StdDev = 0.247$ ），提示该年度内生态质量受人为干扰因素影响显著。

通过 RSEI 与 ENDISI 的时序分析和空间可视化，对研究区近年来的城市发展与生态响应特征进行了深入刻画，为后续的城市可持续发展监管提供了可靠数据基础。未来研究可进一步引入土地利用变化、植被覆盖指数等多源指标，建立更全面的生态-城市耦合监测模型。

为了进一步验证 DSen2 方法在遥感实际应用中的增益效果，本文对比分析了不同影像输入下的城市指数提取结果（均为 2024 年 6 月 17 号的遥感影像），包括：原始 20m 分辨率影像、Bicubic 插值法超分影像以及基于 DSen2 模型生成的 10m 重建影像。比较内容涵盖特定指数提取（RSEI 和 ENDISI）和不透水层面积计算，分别从所得结果的空间分布特征、平均值差异与真实参考数据的接近程度等维度展开评估。真实值用的是 Landsat-8 的数据，虽然其本身并不具备 10m 分辨率，但通过 Pan-sharpening 与 Bicubic 重采样处理后，其空间结构特征可作为 DSen2 超分图像的相对参考。对比结果如表 12 所示。

表 12 2024 年研究选区的数值对比

	原图（20m）	Bicubic（10m）	DSen2（10m）	真实（10m）
RSEI 均值	0.562	0.577	0.591	0.594
RSEI 方差	0.174	0.201	0.218	0.205

ENDISI 均值	0.491	0.518	0.545	0.549
不透水面积	125.3	137.1	147.6	150.2

如表 12 所示，在同一区域内不同超分方法的指数提取结果存在显著差异。原始 20m 图像在 RSEI 与 ENDISI 均值上整体偏低，显示其在空间结构表达与地物边界识别上的不足。Bicubic 方法在一定程度上提升了指数分辨率，但仍存在平滑过度、边界模糊等问题。而 DSen2 所生成的图像在指数均值、方差与空间图斑表现上均最接近参考影像（Landsat-8 重采样结果），验证其在城市指数提取与不透水面计算中的优势。尤其在 ENDISI 提取中，DSen2 方法识别出的不透水面积为 147.6 km^2 ，明显优于原图的 125.3 km^2 ，误差控制在 2% 以内，具备较强实际应用潜力。

综上所述，DSen2 所生成的超分图像不仅提升了城市指数的提取精度，也在遥感业务层面具备更高的应用价值，验证了其作为城市遥感数据前处理方案的可行性与优势。

第五章 讨论

DSen2 模型在城市遥感图像超分辨率重建方面表现出色，尤其在北京亦庄—朝阳区域的应用中，在选取指标上均优于其他方法。这一结果与 Lanaras 等人的研究一致，指出 DSen2 在城市场景中具有更高的空间细节还原能力和光谱一致性。虽然成功验证了深度学习方法在研究区域的优异表现，并总结了各个方法的优劣，本研究存在各种不足以及对未来潜在研究可能的展望。

5.1 评估流程的潜在短板

首先，本研究采用的评估重建方法思路是将 20m 波段降采样至 40m，再进行超分至 20m，这种方法虽然是当前主流的人工退化重建评估框架（Wald's protocol），能够在缺乏真实高分辨率数据的情况下，模拟超分过程以验证重建效果，但其本质仍是“伪真实数据”的间接对比，可能无法完全代表实际从 20m 到 10m 的真实超分效果[14]。该策略在多篇文献中被采用，用于评估超分模型在保持空间细节与光谱一致性方面的能力，但仍存在一定局限性。

为弥补这一问题，部分研究者探索了利用真实 10m 影像或高分辨率数据进行直接对比验证的方式。例如，Xiao Qian 等人[15]提出的 SelfS2 方法，通过深度图像先验与卷积神经网络，在不依赖外部高分辨率标注数据的情况下，实现了 Sentinel-2 多光谱图像从 20m 和 60m 分辨率到 10m 的端到端超分处理。这类方法通常基于神经网络结构本身的约束机制，在训练过程中自构标签，因此更接近于“自监督学习”的语义范畴，尽管本研究并未采用此类模型，但其在实际应用中的可迁移性与泛化能力仍值得关注。

又如 Galar 等人[14]则利用 WorldView 等商业高分辨率卫星数据作为“真实参考图像”，更真实地检验了不同超分方法在真实城市环境中的表现，部分解决了传统人工退化策略与实际影像之间存在的尺度差异问题。

在本研究中，尽管在应用验证层面引入了 Landsat-8 影像，并通过 Pan-sharpening 融合及 Bicubic 重采样构建了 10m 分辨率的“准真实参考图像”，以用于对 DSen2 方法超分重建效果的实证评估，但该参考图像存在局限性。首先，Landsat-8 原始多光谱波段的空间分辨率为 30m，即便结合 15m 的全色波段进行融合，其在空间细节的恢复能力方面仍与真实的 10m 级影像存在一定差距。其次，Landsat 与 Sentinel-2 在成像时间、轨道设计及传感器光谱响应等方面存在本质差异，即使尽量选择时相接近的影像组合，无法消除因成像时差带来的地物状态变化与辐射不一致性。这种差异可能对遥感指数（如 RSEI、ENDISI）计算结果产生扰动，从而对超分方法评估结果的准确性造成一定影响。

以表 12 中 2024 年的评估结果为例，DSen2 方法在指数提取与空间分布上与重采样后的 Landsat-8 参考图像高度一致，验证了其良好的实际应用性能。然而，从多个年份的整体对比来看，这种一致性存在一定波动。例如，在 2019 年 6 月的分析中，Landsat 图像中部分区域因云影干扰或辐射误差导致指数提取偏差较大，未能准确反映城市建设与生态格局的实际状态，影响了对超分方法效果的判断。

因此，未来研究可进一步尝试引入空间分辨率更高的遥感数据（如 GF-2、ZY-3、WorldView 等）或结合地面调查与实测数据，构建更高精度的验证框架，以提升对超分方法实际适用性的综合评估能力。

此外，虽然本研究采用了 PSNR、SSIM、SAM 和 RMSE 四种典型的客观指

标，并辅以主观的视觉对比与多类地物（如水体、道路、建筑等）重建效果的分项分析，力求实现全面化评估，但仍存在部分局限。参考 Chen 等人[16]的文献综述建议，目前常用的评估指标可能与人眼感知存在偏差，难以准确捕捉图像细节恢复的真实效果。未来研究可进一步引入感知质量指数（如 PI）与空间频率（SF）等更具人眼敏感特征的评价体系，以增强对视觉真实感的量化表达。

5.2 PCA 融合方法的劣势分析以及现阶段的超分方法研究趋势

PCA 是线性变换模型，依赖于输入波段间的协方差结构来提取主成分。因此，输入的每个波段在融合结果中所占比例受其与其他波段的相关性影响很大，如果没有高相关性，融合出的主成分图像可能会“偏离”目标波段，产生光谱畸变。对于本研究的哨兵二号卫星，从前文的相关性结果展示（表 4）可知各个低分波段没有表现出和任何一个高分波段强相关的趋势。所以会导致 PCA 在该研究的结果不尽人意。虽然也尝试了优化主成分构建方式或引导波段选择，其性能有小幅度提升。例如，本研究尝试将原始 PCA 的主成分输入由多波段组合修改为与最相关波段的加权和，改善了光谱一致性与图像质量。这表明，在特定设计与应用情境下具备优化空间，但不大。

近年来更先进的超分辨率方法逐渐采用容错性更强的引导机制。比如，ATPRK（区域-点回归克里金）方法采用多个高分波段（如 B02 - B04）作为回归模型输入，并针对每个目标波段独立训练一组回归系数及残差克里金插值模型。该策略实现了对各目标波段引导过程的独立建模，即使相关性较弱，也能通过稳定的回归映射与空间插值达到较好重建效果。

基于陈等人[16]关于超分方法的文献综述，未来的研究会在深度学习方法中进一步优化，比如组合传感器特性与深度学习模型，提升重建的物理一致性与可解释性；探索模型压缩、蒸馏与 Transformer 结构的轻量替代方案，保持精确度的同时压缩深度学习模型参数量大的问题。

5.3 方法在不同地物类型上的适应性表现分析

在遥感图像超分辨率重建任务中，不同方法在地物复杂性、空间结构特征和光谱响应上的适应性存在显著差异。本研究在对比多种方法后发现，深度学习方法 DSen2 和地统计方法 ATPRK 均展现出较强的整体性能，但在具体地物类型上的表现仍存在分化。

以本研究的北京亦庄 - 朝阳区域为例，DSen2 对于各类典型城市地物（如水体、植被、建筑屋顶、道路等）的光谱重建精度均优于其他方法。比如，图 9 折线图组所示的光谱一致性分析中，DSen2 曲线在所有单一地物类型中与地面真值（GT）最为贴合，反映出其较强的跨地物泛化能力。

相比之下，ATPRK 方法在部分中红外波段（如 B05、B11、B12）上的还原效果更为出色，但在 B06 - B08A 波段（通常用于捕捉空间纹理、边界信息）上则表现欠佳，尤其体现在道路类线性地物的恢复中（详见图 9 光谱折线图组-道路）。这类地物具备结构清晰、边界锐利的特点，而 ATPRK 在回归与残差克里金建模中，可能将这类空间异质性过度平滑，造成边缘模糊、细节损失。这一现象提示，ATPRK 更适合处理光谱特征主导、空间变化缓和的波段和目标类型，如中红外波段中的热响应特征和植被水分信息。

方法表现的地区依赖性也被其他研究所证实。Vasilesc 等人[17]在评估 CNN-GPR 与 ATPRK 方法在意大利、罗马尼亚和埃塞俄比亚等地区的超分效果时发现，

ATPRK 在意大利和罗马尼亚表现优于 DSen2，而 DSen2 在埃塞俄比亚沙漠区具备更高的表现力。该研究强调，地物类型与传感器信噪比、地表反射率动态范围等因素的差异均会影响 SR 模型的适应性。因此，本研究认为，针对具体地物与地区特征，选择合适的超分策略，或构建具备区域泛化能力的混合模型，将是未来研究的重要方向。

5.4 生态指数

由于 Sentinel-2 数据缺乏热红外波段，导致无法直接计算地表温度 (LST)，从而限制了生态指数的完整性。未来的研究可以考虑将 Sentinel-2 数据与其他卫星数据（如 Landsat 8 或 MODIS）融合，以获取高分辨率的 LST 信息，从而提高生态指数的准确性和实用性。

第六章 总结

本研究聚焦于 Sentinel-2 多光谱遥感影像在城市场景下的空间细节增强问题，系统评估了六种主流超分辨率重建方法的性能表现，包括传统插值方法（Bicubic）、融合方法（Brovey、PCA 及其优化方案）、机器学习模型（Random Forest）、地统计方法（ATPRK）以及深度学习方法（DSen2）。通过构建基于 Wald's protocol 的人工退化重建框架（即将 20m 图像降采样至 40m，再重建回 20m），在北京市亦庄 - 朝阳区域开展了统一评估实验，结合多波段、多指标、多地物类型展开性能分析，取得以下主要结论：

1. **深度学习模型 DSen2 综合性能最优。** 在所有评估指标中（PSNR、SSIM、SAM、RMSE），DSen2 均表现出高度稳定性与最优值，尤其在城市典型地物（如建筑、道路、水体）上，其重建图像具备更清晰的结构边缘与更高的光谱一致性，适合用于大规模城市影像的精细重建任务。
2. **ATPRK 方法在光谱保持方面表现突出，适用于资源有限或计算成本受限场景。** 其在不依赖训练样本的条件下，能够实现稳健的光谱重建，在中红外波段表现尤为优异，显示出其作为可解释性强、结构合理的方法，在部分应用中仍具备竞争力。
3. **随机森林（RF）在部分波段中表现优异，但稳定性较差。** 尽管在植被敏感波段（如 B05）上，RF 可达到最高 PSNR 与最低 RMSE，但其跨波段波动较大，光谱一致性和结构保持不如 DSen2 与 ATPRK 稳定，难以推广至多期或多区域影像分析中。
4. **PCA 方法在未优化条件下表现最差，但通过主成分引导策略略有提升。** 引入相关性筛选与加权策略后，PCA 的空间和光谱表现均有改进，表明该方法仍具一定优化潜力，但仍难以胜任高精度城市遥感重建任务。
5. **在城市时序分析应用中，超分处理显著提升了生态指数与不透水指数的提取精度。** 本文基于 DSen2 重建的 10m 统一分辨率数据，成功开展了 2017 - 2024 年间城市扩张与生态变化监测。RSEI 反映出区域生态状况整体稳定，ENDISI 指数显著上升，不透水层面积扩展约 76%，准确刻画了城市发展轨迹。
6. **DSen2 所生成影像在实际遥感应用中展现出显著增益。** 通过与原始图像、Bicubic 方法以及 Landsat-8 构建的“准真实图像”对比，DSen2 在空间结构还原、指数均值与波动性等方面均最接近参考值，验证了其在城市遥感业务中的可行性与优越性。
7. **验证机制尚存在局限性，未来需引入更高分辨率数据。** 虽然本研究引入了 Landsat-8 通过 pan-sharpening 构建的 10m 影像作为参考，但其分辨率与波段配置仍与 Sentinel-2 存在差异，建议未来结合 GF-2、ZY-3、WorldView 等更高分辨率遥感数据及地面调查资料，提升验证框架的可靠性。
8. **未来研究方向可向多源数据融合与模型轻量化发展。** 可进一步尝试结合 Sentinel-2 与 MODIS、Landsat 数据融合，实现时空分辨率双重提升；或在深度学习模型中引入多任务学习、传感器物理特征引导、Transformer 结构优化等机制，提升模型解释性、适应性与泛化能力，服务于大尺度遥感监测与智能城市建设。

综上所述，本文不仅系统评估了多种超分方法在城市遥感中的适用性，也将最优结果有效应用于生态监测实证分析，为城市扩张与环境演变提供了更为精细的遥感支持。研究结论为未来城市遥感精细化处理提供了坚实的数据基础与方法借鉴。

参考文献

- [1] 田颖, 陈卓奇, 惠凤鸣, 等. 欧空局哨兵卫星 Sentinel-2A/B 数据特征及应用前景分析[J]. 北京师范大学学报(自然科学版), 2019, 55(01): 57 - 65.
- [2] 李伟, 闫浩文, 周亮, 等. 测绘遥感地理信息新技术服务于数字中国智慧社会建设的研究进展[J/OL]. 测绘地理信息: 1 - 10[2025-04-16].
- [3] GHARBIA R, EL BAZ A H, HASSANIEN A E, 等. Remote sensing image fusion approach based on Brovey and wavelets transforms[A]// KÖMER P, ABRAHAM A, SNAŠEL V. Proceedings of the Fifth International Conference on Innovations in Bio-Inspired Computing and Applications (IBICA 2014)[C]. Cham: Springer, 2014: 319–328. (Advances in Intelligent Systems and Computing, vol 303). DOI:10.1007/978-3-319-08156-4_31.
- [4] SHERMEYER J, VAN ETTEN A. The effects of super-resolution on object detection performance in satellite imagery[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW). IEEE, 2019: 1–10. DOI:10.1109/CVPRW.2019.00184.
- [5] LANARAS C, BIOUCAS-DIAS J, GALLIANI S, 等. Super-resolution of Sentinel-2 images: Learning a globally applicable deep neural network[J]. ISPRS Journal of Photogrammetry and Remote Sensing, 2018, 146: 305–319.
- [6] 成科扬, 荣兰, 蒋森林, 詹永照. 基于深度学习的遥感图像超分辨率重建方法综述[J]. 郑州大学学报(工学版), 2022, 43(5): 8 - 16.
- [7] SØRMO E S, UNGARO O M, SCHINDLER J, 等. A comparison of optimized Sentinel-2 super-resolution methods using Wald's protocol and Bayesian optimization[J]. Remote Sensing, 2021, 13(11): 2192. DOI:10.3390/rs13112192.
- [8] 林辉. 近 20 年京津冀地区不透水面和植被覆盖度时空变化分析及生态环境质量评价[D]. 江苏海洋大学, 2022. DOI:10.44354/d.cnki.gjsuy.2022.000036.
- [9] DONG R, ZHANG L, LI W, 等. An adaptive image fusion method for Sentinel-2 images and high-resolution images with long-time intervals[J/OL]. International Journal of Applied Earth Observation and Geoinformation, 2023, 121: 103381. DOI:10.1016/j.jag.2023.103381[2025-03-28].
- [10] CHEN J, CHEN S, YANG C, 等. A comparative study of impervious surface extraction using Sentinel-2 imagery[J]. European Journal of Remote Sensing, 2020, 53(1): 274–292.
- [11] 徐涵秋. 城市遥感生态指数的创建及其应用[J]. 生态学报, 2013, 33(24): 7853 - 7862.
- [12] 彭实. 级联式高光谱遥感图像空间分辨率增强方法[D]. 首都师范大学, 2014.
- [13] WANG Q, SHI W, LI Z, 等. Fusion of Sentinel-2 images[J/OL]. Remote Sensing of Environment, 2016, 187: 241–252. DOI:10.1016/j.rse.2016.10.016.
- [14] GALAR M, SESMA R, AYALA C, 等. Super-resolution of Sentinel-2 images using convolutional neural networks and real ground truth data[J/OL]. Remote Sensing, 2020, 12(18): 2941. DOI:10.3390/rs12182941[2021-01-28].
- [15] QIAN X, JIANG T X, ZHAO X L. SelfS2: Self-supervised transfer learning for Sentinel-2 multispectral image super-resolution[J/OL]. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 2023, 16: 215–227. DOI:10.1109/JSTARS.2023.3233503[2025-04-15].
- [16] CHEN C, WANG Y, ZHANG N, ZHANG Y, ZHAO Z. A review of hyperspectral image super-resolution based on deep learning[J]. Remote Sensing, 2023, 15(11): 2853. DOI:10.3390/rs15112853.
- [17] VASILESCU V, DATCU M, FAUR D. Sentinel-2 60-m band super-resolution using hybrid CNN-GPR model[J]. IEEE Geoscience and Remote Sensing Letters, 2023, 20: 1–5. DOI:10.1109/LGRS.2023.3240406.

附录 A: ATPRK 超分辨率方法的 MATLAB 实现

A.1 回归建模与克里金残差插值主函数

```
function [alpha, RB, Z] = ATPRK_PANsharpen(Coarse, PAN, Sill_min, Range_min, L_sill,
L_range, rate, H, w, PSF)
```

% 输入参数说明:

% Coarse —— 低分辨率目标波段

% PAN —— 高分辨率引导波段

% Sill_min, Range_min, L_sill, L_range, rate —— 变异函数拟合初值与调节参数

% H —— 插值搜索距离

% w —— 模糊模板窗口大小

% PSF —— 点扩散函数 (如高斯模板)

[a1, b1] = size(Coarse);

[a2, b2] = size(PAN);

s = a2 / a1; % 缩放因子

% === Step 1: 回归建模 ===

```
PAN_upscaled = downsample_plane(PAN, s, w, PSF); % PSF 模糊 + 下采样
```

```
PAN_upscaled_col = [reshape(PAN_upscaled, [], 1), ones(numel(PAN_upscaled), 1)];
```

```
Coarse_col = reshape(Coarse, [], 1);
```

```
alpha = double(PAN_upscaled_col) \ double(Coarse_col); % 最小二乘回归系数
```

```
Z_R = reshape([reshape(PAN, [], 1), ones(numel(PAN), 1)] * alpha, size(PAN));
```

% === Step 2: 残差建模 ===

```
Z_R_upscaled = downsample_plane(Z_R, s, w, PSF);
```

```
RB = Coarse - Z_R_upscaled; % 残差图像
```

```
RB_extend = padarray(RB, [w, w], 'replicate'); % 扩展边界防止边缘效应
```

% === Step 3: 变异函数拟合 ===

```
for h = 1:H
```

```
    rh(h) = semivariogram(RB, h); % 半变异函数
```

```
end
```

```
x0 = [0.1, 1]; % 初始拟合参数
```

```
[xa1, ~] = lsqcurvefit(@myfun2, x0, s:s:s*H, rh);
```

```
xp_best = ATPK_deconvolution0(H, s, xa1, Sill_min, Range_min, L_sill, L_range, rate);
```

% === Step 4: 克里金插值 (ATPK) ===

```
yita1 = ATPK_noinform_yita_new(s, w, xp_best, PSF); % 半变异函数构建权重矩阵
```

```
P_vm = ATPK_noinform_new(s, w, RB_extend, yita1); % 插值残差项
```

```
Z_ATPK = P_vm(w*s+1:end-w*s, w*s+1:end-w*s); % 去除边缘
```

```
Z = Z_R + Z_ATPK; % 组合回归+残差超分结果
```

```
end
```

A.2 PSF 模板生成与变异函数拟合

%%% 2*w+1 是 PSF 的窗口宽度; b 是核函数标准差; s 是降采样因子

```
function H = PSF_template(s, w, b)
```

```

for i = 1:(2*w+1)*s
    for j = 1:(2*w+1)*s
        Dis2 = (norm([i-0.5, j-0.5] - [(2*w+1)*s/2, (2*w+1)*s/2]))^2;
        H0(i, j) = exp(-Dis2 / (2 * b^2));
    end
end
Hsum = sum(H0(:));
H = H0 / Hsum; % 归一化为权重和为 1 的高斯核
End

function rh=semivariogram(J,h);
[a,b]=size(J);
N1=0;r1=0;
for i=h+1:a
    for j=1:b
        r1=r1+(J(i,j)-J(i-h,j))^2;
        N1=N1+1;
    end
end
N2=0;r2=0;
for i=1:a-h
    for j=1:b
        r2=r2+(J(i,j)-J(i+h,j))^2;
        N2=N2+1;
    end
end
N3=0;r3=0;
for i=1:a
    for j=h+1:b
        r3=r3+(J(i,j)-J(i,j-h))^2;
        N3=N3+1;
    end
end
N4=0;r4=0;
for i=1:a
    for j=1:b-h
        r4=r4+(J(i,j)-J(i,j+h))^2;
        N4=N4+1;
    end
end
r=r1+r2+r3+r4;
N=N1+N2+N3+N4;
rh=r/(2*N);

```

A.3 残差插值过程 (ATPK_noinform 模块)

```

function P_vm = ATPK_noinform_new(s, W, S, yitaX)
    [c, d] = size(S);
    Simulated_part = zeros(c - 2 * W, d - 2 * W);
    [M1, N1] = find(Simulated_part == 0); numberM1 = length(M1);
    M1 = M1 + W; N1 = N1 + W;
    P_vm = zeros(c * s, d * s);
    for k = 1:numberM1
        for i = 1:s
            for j = 1:s
                Local_W = S(M1(k)-W:M1(k)+W, N1(k)-W:N1(k)+W);
                co = D3_D2(yitaX(i, j, 1:end-1));
                P_vm((M1(k)-1)*s + i, (N1(k)-1)*s + j) = co' * reshape(Local_W, (2*W+1)^2,
            1);
            end
        end
    end
end

function yita = ATPK_noinform_yita_new(s, W, xX, PSF)
    TVV = T_coarse_coarse2(W, s, xX, PSF);
    for i = 1:s
        for j = 1:s
            coordinate_vm = [W * s + i, W * s + j];
            rvV = r_fine_coarse2(coordinate_vm, W, s, xX, PSF);
            Matrix = [TVV, ones((2*W+1)^2, 1); ones(1, (2*W+1)^2), 0];
            Vector = [rvV; 1];
            yita(i, j, :) = inv(Matrix) * Vector;
        end
    end
end

```

致谢

与其说本科四年的求学生涯，我更愿将它称为一段绚丽多彩的旅程。我受到了首都师范大学严谨、包容的学术训练，也有幸去往加拿大滑铁卢大学收获挑战不断、文化开放的沉浸式体验。正是学习了遥感科学这门融合技术与现实问题的交叉学科，启发我最终选择走向计算机科学的道路。一直以来，我都对算法怀有浓厚兴趣，感谢毕业设计给了这个机会——去完成一项我真正热爱、并始终想亲手实践的课题：算法对比研究。这段从零搭建、独立推进的过程，不仅是我学术探索的重要确认，更见证了我在异国他乡一步步找到了热爱与方向。

感谢我的父母，是你们无条件的支持与理解，让我得以无惧地奔赴远方。感谢滑铁卢大学那群可爱的朋友们，在异国求学的日子里，是你们的陪伴让我感受到家一般的温暖。特别感谢我的男朋友、也是我最亲密的本科伙伴——许书唯同学，从最初的外培同行者到如今的彼此珍贵，你的照顾与陪伴是我最宝贵的精神财富。

我曾被高考打击而一蹶不振，但我现在会释怀地想，也许那时错的每道题都是命运温柔的引导——它让我来到了这个外培计划，让我遇见对的人和自己想为之努力的方向。一路走来，我满怀感恩。

我也曾怀疑过，从遥感转向计算机是否正确，但我不后悔。未来的路还很长，希望我在美国的研究生生活一切顺利，也希望自己始终保持热爱，坚定前行。Everything happens for the best:)